UNIVERSITÁ DEGLI STUDI DI MILANO-BICOCCA

Scuola di Economia e Statistica

Corso di laurea in

STATISTICA E GESTIONE DELLE INFORMAZIONI

Percezione pubblica dell'Intelligenza Artificiale: Un'analisi computazionale del dibattito su Reddit tramite Emotion Analysis, Topic Modeling e XAI.

Relatore: Prof. Lorenzo Malandri

Tesi di Laurea di:
Andrea Porro
Matr. N. 896050

Anno Accademico 2024/2025

Ai miei nonni,
i miei angeli custodi.

Che ogni mio traguardo sia anche il vostro,
e che possa sempre rendervi fieri di me.

Indice

Abstract . . . 7
Introduzione . . . 9
Il contesto . . . 9
La rilevanza del problema . . . 9
Obiettivo della tesi . . . 10
Anticipazione delle metodologie utilizzate . . . 10
Struttura della tesi . . . 10
1 Stato dell'arte . . . 13
1.1 L'analisi del sentimento e delle emozioni nel discorso pubblico 13
Evoluzione della sentiment analysis . . . 13
Oltre il sentimento: textual emotion analysis - TEA . . . 14
Applicazioni su social media . . . 15
1.2 Il dibattito pubblico e accademico sull'impatto dell'IA . . . 16
Trasformazione del Lavoro . . . 16
Etica, Sicurezza e Rischi . . . 17
Regolamentazione e Governance . . . 18
1.3 Metodologie computazionali per l'analisi del discorso online . . 19
Topic modeling . . . 19
Explainable Ai . . . 21
1.4 Sintesi e posizionamento della Ricerca . . . 22
2 Metodologie . . . 23
2.1 Fonte dei dati e metodo di raccolta . . . 23
La piattaforma Reddit . . . 23
Il Subreddit Futurology . . . 23
Strumenti e procedura di raccolta . . . 24
2.2 Costruzione e preprocesso del testo . . . 24
Pulizia del dataset . . . 24
Preprocesso del testo . . . 25
2.3 Analisi esplorativa dei dati - EDA . . . 26
Statistiche descrittive . . . 26
Introduzione al text mining . . . 26
2.4 Selezione dei modelli per la sentiment analysis . . . 26
Sentiment Analysis - SA . . . 26
Textual Emotion Analysis - TEA . . . 28
2.5 Modello di Topic Modeling . . . 29
Scelta del modello . . . 29
Titoli dei topic . . . 29
2.6 Modello predittivo e di spiegabilità (XAI) . . . 29
Definizione del problema . . . 29

Scelta del modello 30
Metodologia di spiegabilità 31
3 Esperimenti e risultati 33
3.1 Panoramica Descrittiva 33
Risultati dell'analisi descrittiva 33
Risultati del text mining 38
3.2 Analisi emotiva nel dibattito 40
Risultati della Sentiment Analysis 40
Risultati della Textual Emotion Analysis 42
3.3 Analisi del topic modeling 47
Risultati generali del topic modeling 47
Analisi del sentiment per topic 48
Analisi delle emotion per topic 50
3.4 Analisi dello XAI 51
Scelta del modello 51
Analisi dello SHAP 51
4 Discussione finale e conclusioni 57
4.1 Discussione dei principali risultati 57
4.2 Limiti dello studio 57
4.3 Direzioni per una ricerca futura 58
4.4 Conclusioni 58

Abstract

In un'era definita dall'ascesa dell'IA, qual è la reale percezione del pubblico? La tesi supera i metodi tradizionali, come i sondaggi cartacei, analizzando il discorso spontaneo di oltre 50.000 commenti provenienti dalla piattaforma Reddit. Attraverso un approccio computazionale che unisce Emotion Analysis, Topic Modeling e Explainable AI (XAI), lo studio scompone il dibattito pubblico per rispondere a domande chiave: quali temi specifici guidano la conversazione? Quali sono le reazioni emotive associate? E quali fattori determinano l'influenza di un'opinione? La tesi condotta mira ad offrire una comprensione più profonda della sfera pubblica, fornendo al contempo un modello metodologico per analizzare dibattiti complessi. Lo studio svolto mira a comprendere la natura, a volte contraddittoria, delle conversazioni sull'IA, al fine di allineare lo sviluppo di quest'ultima con l'opinione degli utenti. Questo è fondamentale, poiché uno sviluppo rapido e precoce rischia di non guadagnare la fiducia delle persone.

Introduzione

Il contesto

Nel corso del tempo, l'Intelligenza Artificiale (IA) ha vissuto un profondo cambiamento, passando da una disciplina accademica di nicchia a un fenomeno tecnologico e sociale globale. Le fondamenta teoriche dell'IA risalgono al workshop di Dartmouth del 1956 e, per decenni, lo sviluppo dell'IA è rimasto confinato all'interno della comunità scientifica. Tuttavia, la percezione comune di una sua "nascita" nel XXI secolo non è del tutto errata. Infatti, a partire dal primo decennio degli anni 2000, si è assistito a un'accelerazione esponenziale del suo sviluppo, trainata principalmente dalla rinascita delle reti neurali profonde (deep learning). Questa rivoluzione tecnica ha prodotto numerosi risultati che hanno permesso di catturare l'immaginazione del pubblico, come la vittoria di AlphaGo contro il campione del mondo di Go, rendendo per la prima volta concreta la potenza delle moderne architetture di IA. Parallelamente a questi successi, è emersa una crescente consapevolezza dei potenziali rischi e delle implicazioni etiche. Tale consapevolezza fu portata all'attenzione globale da eventi come la conferenza di Asilomar del 2009, dove gli stessi ricercatori discussero la necessità di uno sviluppo sicuro e controllato, per la paura della perdita di controllo umano sui sistemi basati su computer. Tuttavia, è stato l'avvento dei modelli di IA generativa accessibili al grande pubblico, come ChatGPT o Gemini, ad accelerare in modo definitivo la transizione. Questi strumenti hanno trasformato l'IA da concetto astratto a esperienza quotidiana per milioni di persone, intensificando ulteriormente il dibattito su larga scala. Questa intensificazione ha polarizzato la discussione, contrapponendo da una parte i timori per l'impatto sul mondo del lavoro o della creatività e i rischi per la sicurezza, dall'altra le grandi aspettative per rivoluzioni in campo medico, l'accelerazione della scoperta scientifica e il progresso tecnologico. L'IA si è quindi affermata irreversibilmente come un fulcro del dibattito pubblico contemporaneo, influenzando le speranze e le preoccupazioni della società moderna.

La rilevanza del problema

Comprendere la percezione pubblica dell'Intelligenza Artificiale non è più un semplice esercizio accademico, ma un'importante analisi che consente di esaminare in modo tangibile le opinioni delle persone. Le narrazioni che prevalgono nel dibattito pubblico esercitano un'influenza diretta sulla politica e, di conseguenza, anche un'influenza sul controllo. I timori infondati potrebbero condurre a una regolamentazione eccessiva che rischierebbe di rallentare o addirittura fermare l'innovazione. D'altra parte, un'euforia senza alcun tipo di critica rischierebbe di ritardare l'implementazione delle necessarie tutele etiche. Oltre all'impatto normativo, analizzare la percezione è fondamentale per comprendere i livelli di fiducia e accettazione sociale. Questi fattori sono cruciali per l'integrazione dell'IA, soprattutto con questioni fondamentali in gioco, come ad esempio il futuro del mondo del lavoro. Diventa quindi fondamentale che questa discussione sia fondata, poiché proprio in questa fase iniziale esiste ancora la possibilità di plasmarla in una direzione positiva. Nell'era contemporanea, queste dinamiche di percezione si formano e si amplificano soprattutto sulle piattaforme social. Piattaforme come Reddit, con le loro community, sono "specchi digitali" del dibattito pubblico, offrendo accesso senza filtri ad opinio-

ni spontanee e rendendo possibile procedere con analisi che permettono di cogliere eventuali tendenze e opinioni.

Obiettivo della tesi

Spesso, per analizzare il dibattito riguardante l'IA si tende a basarsi su studi ristretti, come ad esempio tramite sondaggi che però non colgono la spontaneità delle persone, oppure concentrandosi su singoli eventi mediatici di forte rilevanza, i quali non riflettono le opinioni spontanee delle persone. Per questo motivo, basarsi su campioni così limitati e circoscritti non permette di rappresentare in modo accurato la reale opinione delle persone. L'obiettivo principale di questa tesi è proprio quello di colmare parte di queste lacune, fornendo un'analisi dettagliata del discorso pubblico sull'Intelligenza Artificiale tramite la raccolta e l'analisi di commenti spontanei provenienti dalla piattaforma Reddit. Per raggiungere tale scopo, lo studio si occuperà di scoprire le emozioni associate a ciascun commento e di identificare quali siano i temi dominanti e le narrazioni ricorrenti nella conversazione pubblica. Infine, verranno analizzati gli elementi che rendono un'opinione più influente di un'altra all'interno della piattaforma social.

Anticipazione delle metodologie utilizzate

Al fine di rispondere ai dubbi che sono stati posti, lo studio ha utilizzato un approccio misto. L'indagine è iniziata con un'analisi statistica descrittiva ed esplorativa del dataset, con lo scopo di comprendere le caratteristiche dei dati nel modo più completo possibile. Successivamente, l'analisi si è concentrata sull'utilizzo di tecniche avanzate di Natural Language Processing (NLP). In maniera più specifica, per quanto riguarda l'analisi delle emozioni, sono stati utilizzati algoritmi di Emotion Analysis. Successivamente, per l'identificazione dei temi latenti, si è fatto ricorso a modelli di Topic Modeling. Infine, per interpretare in maniera più approfondita i fattori che determinano l'influenza dell'opinione pubblica, sono stati impiegati metodi basati su modelli di Explainable AI (XAI). L'utilizzo di tutte queste metodologie ha consentito di offrire un'ottima comprensione delle dinamiche che caratterizzano il dibattito pubblico sull'IA.

Struttura della tesi

Lo studio è stato diviso in quattro capitoli ben distinti:

1. Stato dell'arte: In questo capitolo viene esaminata la letteratura scientifica di riferimento sui temi dell'analisi delle emozioni, dell'impatto sociale dell'IA e delle metodologie utilizzate, come il Topic Modeling e l'Explainable AI.

2. Metodologie: In questo capitolo vengono descritte in dettaglio le metodologie utilizzate, illustrando ogni fase del processo, dalla raccolta dei dati fino ai modelli impiegati per l'analisi XAI.

3. Esperimenti e risultati: In questo capitolo si presentano in modo oggettivo i risultati ottenuti dalle analisi.

4. Discussione e conclusioni: In questo capitolo vengono interpretati i risultati, contestualizzandoli allo stato dell'arte. Si evidenziano i limiti dello studio e si propone una direzione per la ricerca futura.

1 Stato dell'arte

1.1 L'analisi del sentimento e delle emozioni nel discorso pubblico

Evoluzione della sentiment analysis

La Sentiment Analysis (SA) o Opinion Mining (OP) è lo studio computazionale delle opinioni e degli atteggiamenti delle persone. Con tecnologie sempre più all'avanguardia, anche questo campo di ricerca si è dovuto evolvere nel corso del tempo per migliorare la propria classificazione.

Tra la fine degli anni novanta e i primi anni duemila, il metodo per eccellenza nella classificazione del sentimento era basato su dizionari (lexicon-based). Questo metodo si basa sull'uso di una raccolta di termini con sentiment noto. Più precisamente, questo approccio può essere suddiviso in due varianti: La prima è basata su dizionari (dictionary-based). Si parte da un piccolo gruppo di parole raccolte manualmente e con un orientamento noto. Ad esempio, le parole positive possono essere buono o felice, mentre i termini negativi possono essere cattivo o triste. Successivamente, questo gruppo viene ampliato cercando sinonimi e contrari tramite l'utilizzo di dizionari digitali come WordNet. In questo modo, si ottiene un ampio dizionario di termini con sentiment noti. Il secondo approccio, invece, è basato sul corpus (corpus-based). Come per la variante precedente, anche in questo caso si parte da un gruppo di parole con polarità nota. Tuttavia, invece di utilizzare dizionari esterni, l'approccio basato su corpus analizza un insieme di testi per individuare altre parole che compaiono in contesti simili al gruppo iniziale, utilizzando pattern sintattici o semantici. Rispetto al metodo basato sui dizionari, questo approccio consente di determinare se una parola abbia un significato positivo o negativo anche in base al contesto in cui compare. Gli approcci basati su dizionari rappresentano uno dei primi metodi utilizzati per la Sentiment Classification e Sentiment Analysis. Il principale vantaggio di questo metodo è la sua semplicità ed efficienza dal punto di vista computazionale. Tuttavia, presenta anche numerose limitazioni, tra cui la più importante è l'incapacità di rilevare il complesso contesto semantico. Infatti, questi metodi non sono in grado di rilevare il sarcasmo in quanto non tengono in considerazione il significato semantico dell'intera frase. Inoltre, la polarità di una parola dipende dal contesto nel quale essa appare e spesso questo metodo non è in grado di considerare questo aspetto, classificando erroneamente il sentimento.

Intorno ai primi anni duemila, la Sentiment Analysis è diventata un problema di classificazione del testo, ciò ha permesso l'evoluzione e l'implementazione di metodi di machine learning. L'aumento dell'utilizzo di modelli di machine learning può essere spiegato da più fattori, uno dei quali è una maggiore disponibilità di dataset su cui addestrare gli algoritmi, dovuta soprattutto allo sviluppo del World Wide Web e ai siti di recensioni come Amazon. Come per i metodi dei dizionari, anche i metodi di machine learning per la classificazione del sentiment si dividono in due varianti: La prima consiste nei metodi di apprendimento supervisionato (supervised learning). Questi modelli venivano addestrati su dataset etichettati. Più precisamente, il dataset viene diviso in training e testing. Come dice la parola stessa, nella parte di training il modello viene addestrato e successivamente testato nella parte di testing per valutarne la performance. Se la performance ottenuta risulta ottimale, allora si procede a salvare il modello e a utilizzarlo per classificare nuove osservazioni. Tra i

modelli più diffusi, troviamo: Support Vector Machine (SVM), Naive Bayes (NB) e molti altri. La seconda variante è rappresentata dai metodi di apprendimento non supervisionato (unsupervised learning). Questa variante è utilizzata principalmente quando è difficile reperire documenti etichettati per l'addestramento. In questo contesto, l'obiettivo è identificare la polarità dei testi sfruttando le relazioni semantiche e statistiche tra le parole, come ad esempio valutare quanto una parola sia associata a termini positivi o negativi. Un esempio è il metodo SO-PMI (Semantic Orientation - Pointwise Mutual Information), in cui la polarità di una parola viene stimata analizzando la frequenza con cui essa appare con termini fortemente positivi o negativi. Un altro approccio si basa su modelli generativi e latenti, come il Latent Dirichlet Allocation (LDA), che consente di identificare le strutture tematiche nascoste nei documenti e di analizzare il sentiment associato a ciascun argomento. Come per i metodi basati sui dizionari, anche i metodi di machine learning presentano vantaggi e limitazioni. Uno dei vantaggi è sicuramente il fatto che si ottengono risultati più precisi, specialmente se si riesce a catturare le relazioni semantiche tra le parole. Inoltre, i modelli di machine learning permettono di essere riaddestrati su nuovi dati, in modo da adattarsi meglio ai contesti di utilizzo. Ad esempio, se si vogliono analizzare delle recensioni di film e serie tv si può utilizzare un modello pre-addestrato proprio sulle recensioni televisive. Tuttavia, una forte limitazione è il fatto che i metodi supervisionati richiedono un gran numero di documenti di addestramento etichettati per essere così precisi, rendendoli più lenti e costosi da un punto di vista computazionale. Inoltre, se i dati di training non sono bilanciati in maniera corretta, si rischia che il modello impari il pattern solo del dataset d'addestramento e che quindi perda la sua capacità di generalizzazione.

Negli ultimi anni, i metodi di machine learning si sono evoluti e si sono sviluppati modelli trasformativi (transformer models), appartenenti alle reti neurali e, più in generale, al deep learning. Al momento, i modelli trasformativi sono il metodo più utilizzato quando si tratta di elaborazione del linguaggio naturale (NLP), soprattutto nella Sentiment Analysis. Tra i modelli più diffusi ci sono BERT, RoBERTa, DistillBERT e LLM, un'evoluzione stessa dei transformer. I modelli come quello BERT si basano su un'architettura transformer bidirezionale multilivello, che è capace di comprendere il contesto di una parola considerando sia ciò che c'è prima sia ciò che c'è dopo. I modelli trasformativi sono molto efficaci per la Sentiment Analysis in quanto permettono di catturare le relazioni semantiche complesse, come cogliere l'ironia, l'intensità emotiva e varie altre sfumature linguistiche. Inoltre, vengono prima pre-addestrati su grandi quantità di testi generali e poi perfezionati (fine-tuning) su dataset specifici, come recensioni o post sui social media. Tuttavia, tra le limitazioni che si possono riscontrare in questi metodi c'è l'elevato costo computazionale che richiedono. Inoltre, essendo dei black box models, risultano di difficile interpretazione. Infatti, non sempre è chiaro come si sia arrivati ad una determinata decisione. La ridotta trasparenza rende questi modelli maggiormente problematici in ambiti sensibili come le analisi sanitarie o politiche.

Oltre il sentimento: textual emotion analysis - TEA

Nel corso del tempo e con l'evoluzione degli strumenti di analisi, è emerso un limite fondamentale della Sentiment Analysis. Lo studio della polarità, ovvero la distinzione tra sentiment positivo, negativo o neutro, non è più sufficiente per rappresentare la complessità emotiva del discorso pubblico. Infatti, questo approccio è limitato e

non permette di cogliere la complessità emotiva, poiché ignora le sfumature sottili del cambiamento delle emozioni dell'utente. Ad esempio, la rabbia e la tristezza rappresentano stati emotivi molto diversi, ma nell'approccio tradizionale entrambe vengono classificate come sentiment negativo. Per affrontare discussioni complesse, è quindi necessario un approccio più esaustivo, definito come analisi delle emozioni specifiche (Textual Emotion Analysis - TEA) che permette di prevedere l'emozione provata, come rabbia, paura, gioia, ecc.

Quando si analizzano i modelli che permettono il rilevamento delle emozioni, è fondamentale sapere che l'analisi delle emozioni ha le sue basi nei concetti della psicologia, che mirano a descrivere e classificare i comportamenti umani. Le principali teorie dell'Emotion Analysis basate su categorie specifiche si ispirano principalmente ai lavori di Paul Ekman e Robert Plutchik. Ekman propose un insieme di emozioni di base, le quali sono universali, classificando le emozioni in sei tipi fondamentali: rabbia, disgusto, paura, felicità, tristezza e sorpresa. Queste categorie che Ekman riscontrò nei comportamenti umani sono spesso utilizzate come etichette target quando si tratta di analisi emotiva. D'altra parte, il modello di Plutchik definisce un'insieme di otto emozioni di base bipolari. Le otto emozioni sono quindi organizzate in quattro coppie più precisamente: gioia / tristezza, rabbia / paura, fiducia / disgusto e sorpresa / anticipazione. Quindi, l'analisi delle emozioni (Textual Emotion Analysis) si basa su questi modelli, consentendo ai sistemi di estrarre lo stato emotivo specifico invece di fermarsi alla semplice polarità.

Come per la Sentiment Analysis, anche il campo del riconoscimento delle emozioni ha avuto un'evoluzione nel corso del tempo. I primi approcci si basavano su dizionari di parole emotive (emotion lexicons), che associavano termini specifici a emozioni predefinite. Tuttavia, questi metodi erano limitati perché soggettivi e incapaci di cogliere le relazioni contestuali tra le parole. Queste limitazioni portarono allo sviluppo di approcci learning-based, nei quali i lessici non erano più utilizzati come classificatori primari, ma come caratteristiche da integrare negli algoritmi di machine learning.

Negli ultimi anni, questo campo scientifico si è notevolmente evoluto, passando da approcci basati su regole e lessici ai più recenti sistemi di deep learning come le CNN (Convolutional neural network) e le LSTM (Long short-term memory), capaci di riconoscere pattern complessi nel testo. Successivamente, l'introduzione di modelli pre-addestrati come Word2Vec e GloVe, capaci di catturare le relazioni semantiche tra le parole, e dei modelli trasformativi come BERT, in grado di considerare anche il contesto linguistico, hanno rappresentato un punto di svolta nel riconoscimento delle emozioni, migliorandone la precisione.

Applicazioni su social media

Un importante studio chiave che ha utilizzato tecniche di Sentiment Analysis per analizzare l'opinione pubblica è l'articolo "From Tweets to Polls: Linking Text Sentiment to Public Opinion Time Series". Questo lavoro è stato condotto da Brendan O'Connor, Ramnath Balasubramanyan, Bryan R. Routledge e Noah A. Smith, pubblicato nel 2010, si è concentrato sulla connessione tra l'opinione pubblica ottenuta tramite sondaggi tradizionali e il sentiment misurato attraverso i messaggi provenienti dalla piattaforma social Twitter.

Gli autori hanno dimostrato che i dati testuali, come i messaggi su Twitter possono essere usati come alternativa o complemento ai sondaggi tradizionali. Le misure

di sentiment correlate con i risultati di sondaggi reali raggiungono, in alcuni casi, valori fino all'80% di correlazione. Inoltre, analizzare il sentiment dai tweet ha permesso di catturare tendenze temporali significative, riflettendo l'andamento dell'opinione pubblica. Infine, il sentiment del testo ha permesso di offrire una visione più rapida di eventuali cambiamenti nell'opinione pubblica rispetto ai tradizionali metodi di indagine.

Nonostante ciò, lo studio ha rilevato anche alcune limitazioni, tra cui forti problemi legati al lessico utilizzato e la presenza di rumore all'interno dei messaggi. Inoltre, mentre si analizzano milioni di tweet, i sondaggi dispongono di campioni di dimensioni decisamente più ridotte. Infine, il sentiment giornaliero è altamente variabile, quindi, queste analisi sono principalmente utili quando si parla di trend a lungo termine, piuttosto che di analisi giornaliere.

Va ricordato che tale studio risale al 2010 e da allora, le tecniche di Natural Language Processing e di Sentiment Analysis si sono evolute notevolmente, permettendo oggi una maggiore accuratezza e robustezza nei risultati.

1.2 Il dibattito pubblico e accademico sull'impatto dell'IA

Trasformazione del Lavoro

Nel periodo storico che stiamo vivendo, uno dei temi al centro del dibattito pubblico è la trasformazione del mondo del lavoro a causa dello sviluppo dell'automazione, della robotica e dell'intelligenza artificiale. Come viene evidenziato nel libro 'The second machine age' (2014) di Brynjolfsson e McAfee, le tecnologie stanno ridefinendo l'intero settore lavorativo, dalla produzione fino al ruolo stesso delle persone. Quindi, mentre da un lato troviamo un'aumento della produttività e della ricchezza che viene generata dall'innovazione tecnologica, dall'altro lato vi è il rischio di una disoccupazione di massa e di una maggiore disuguaglianza economica. Alla base di ciò nascono due principali correnti di pensiero. La prima, quella della sostituzione (job displacement) afferma che l'automazione sta progressivamente rimpiazzando i lavoratori umani, specialmente nelle mansioni ripetitive, come l'assemblaggio in una catena di montaggio o nelle operazioni di cassa. La seconda corrente di pensiero è invece quella del potenziamento (job augmentation), che sostiene che la tecnologia possa favorire la nascita di nuove professioni e attività. In entrambi i casi, gli autori affermano che, per adattarsi alla continua evoluzione del mercato del lavoro, è fondamentale sia il reskilling, potenziamento delle competenze, sia l'upskilling, l'acquisizione di nuove competenze.

Un'altro articolo di importante rilevanza è "Automation and New Tasks: How Technology Displaces and Reinstates Labor" di Daron Acemoglu e Pascual Restrepo (2019) che propone un modello teorico basato su delle tasks per analizzare l'impatto della tecnologia sul lavoro. Infatti, secondo questa teoria, la produzione si basa su una serie di compiti che possono essere svolti sia dal lavoro umano sia dalle macchine. Acemoglu e Restrepo identificano due forze principali e contrapposte. La prima è l'effetto di sostituzione (Displacement Effect) che si verifica quando l'automazione permette alle macchine di svolgere compiti precedentemente affidati ad una persona. La seconda è invece l'effetto di reintegrazione (Reinstatement Effect), ovvero quando l'utilizzo della tecnologia permette di creare delle nuove task e ciò genera nuovi lavori. L'articolo si conclude affermando che il problema non è l'automazione in sé, ma il disequilibrio tra l'automazione e l'innovazione del lavoro. Secondo gli autori, è

necessario favorire la creazione di nuovi compiti che permettano lo sviluppo di nuovi posti di lavoro.

Infine, un'importante report è il "The Future of Jobs Report" dell'organizzazione World Economic Forum (WEF). Il report analizza il periodo 2023-2027 e mostra come le trasformazioni siano guidate soprattutto dall'automazione, dall'IA generativa e dalla transizione verde. Il report tratta l'effetto di sostituzione (displacement) e l'effetto di reintegrazione (reinstatement). Nell'effetto di sostituzione si afferma che si prevede una perdita di circa 14 milioni di posti di lavoro e gli ambiti più colpiti saranno quelli amministrativi e contabili. Invece, quando si parla dell'effetto di reintegrazione, si afferma che cresceranno numerosi ruoli legati principalmente alla gestione e all'implementazione della tecnologia. Inoltre, si stima che il reskilling e l'upskilling saranno necessari per numerosi lavoratori che dovranno acquisire competenze di pensiero analitico e creativo.

Etica, Sicurezza e Rischi

Oltre alla trasformazione del mondo del lavoro, ci sono vari ambiti al centro del dibattito pubblico legati all'intelligenza artificiale. Tra questi vi sono sicuramente gli aspetti legati all'etica, alla sicurezza e ai rischi che l'AI comporta.

Tra i concetti chiave di queste questioni vi è sicuramente il bias algoritmico. Questo problema nasce quando gli algoritmi di apprendimento automatico producono risultati discriminatori che riflettono eventuali pregiudizi sociali gia esistenti, come pregiudizi di genere o di etnia. Un articolo fondamentale che tratta di questo tema è il "Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification" pubblicato nel 2018 da Joy Buolamwini e Timnit Gebru. L'articolo ha dimostrato come molti sistemi per la classificazione del genere, basati sul volto delle persone, tendano ad avere prestazioni peggiori nei confronti delle donne con la pelle più scura. Più precisamente, si è riscontrato che i tassi di errore per questo gruppo raggiungevano il 34,7%, mentre il tasso di errore massimo per gli uomini con la pelle più chiara era solo dello 0,8%. In linea di massima, si è scoperto che i classificatori tendevano a classificare meglio i volti maschili rispetto a quelli femminili e i soggetti con una pelle più chiara rispetto a quelli con una pelle più scura. Lo studio ha quindi prove empiriche che dimostrano la presenza del bias algoritmico. È sbagliato pensare che questo errore non costituisca alcun tipo di problema. Infatti, spesso, i sistemi di IA, come quello del riconoscimento facciale, vengono utilizzati anche nei sistemi di giustizia penale per l'identificazione dei sospetti. Quindi, un errore nell'output potrebbe portare all'accusa ingiusta di un innocente.

Un altro articolo di estrema rilevanza quando si parla di etica, sicurezza e rischi è il "The ethics of algorithms: Mapping the debate" pubblicato nel (2016) da Mittelstadt, B. D., Allo, P., Taddeo, M., Wachter, S., Floridi, L. L'articolo si concentra sul problema della trasparenza dei black box models. Quando si parla di trasparenza, si intende la difficoltà nel comprendere la connessione tra gli input, ovvero i dati che si vogliono analizzare, e gli output, ovvero i risultati finali prodotti dal modello utilizzato. Secondo l'articolo, sono due le principali fonti che contribuiscono all'incomprensione. La prima è una complessità tecnica data spesso dalla grande mole di dati che viene analizzata. La seconda è data dai modelli di machine learning che presentano un'incomprensibilità e un'inaccessibilità delle regole decisionali che portano ad un risultato. La non trasparenza dei risultati non è solamente una sfida tecnica, ma ha sollevato nel tempo numerose questioni etiche. Infatti, la logica dietro questi

modelli è spesso incomprensibile e ciò rende difficile la possibilità di contestare le decisioni che esso prende. Ciò può anche portare ad una perdita della fiducia nei confronti di questi algoritmi. Infine, l'articolo afferma che la forte autonomia di questi modelli ha comportato un gap di responsabilità, ovvero, nessuno si assume la responsabilità di eventuali fallimenti, dal momento che nessuno ha il controllo sulle decisioni degli algoritmi.

Un altro testo fondamentale da citare è il libro "Superintelligence: Paths, Dangers, Strategies" del 2014 del filosofo Nick Bostrom. Il libro può essere articolato in tre idee principali. La prima riguarda i percorsi della superintelligenza. L'autore descrive che la superintelligenza potrebbe emergere dal continuo miglioramento dell'AI, dall'ingegneria del cervello umano o dai sistemi collettivi. La seconda idea è quella che riguarda i rischi e i pericoli. Secondo Bostrom, una superintelligenza non correttamente allineata ai valori umani potrebbe diventare incontrollabile, perseguendo i propri obiettivi. Infine, come ultima idea centrale, vi è il problema dell'allineamento dei valori. Infatti, secondo il filosofo, una volta che verrà creata una superintelligenza autonoma, sarà impossibile modificarne il comportamento. Il libro, quindi, apre le porte al dibattito sui rischi a lungo termine dell'AI. A differenza degli articoli citati precedentemente, che mostrano dilemmi attuali, Bostrom intende spostare l'attenzione sui rischi futuri.

Di fronte a queste numerose sfide, sia la comunità scientifica che la società stessa si sono mosse al fine di rendere questo campo più sicuro, trasparente ed etico. I lavori come quelli del filosofo Bostrom hanno portato alla creazione di interi settori di ricerca dedicati interamente alla sicurezza dell'IA. Invece, contro il bias e la trasparenza, negli ultimi anni si è sviluppato rapidamente il campo dell'IA spiegabile (XAI).

Regolamentazione e Governance

Sicuramente, un altro aspetto che suscita un forte dibattito sull'intelligenza artificiale sono gli approcci che i governi adottano per la sua regolamentazione.

Secondo l'articolo "A Critical Take on the Policy Recommendations of the EU High-Level Expert Group on Artificial Intelligence" pubblicato nel 2020 da Veale, M. Il dibattito pubblico globale è polarizzato tra l'approccio adottato dall'Unione Europea, che punta a un controllo e a una regolamentazione più severa, rispetto all'approccio più flessibile e orientato al mondo del lavoro adottato dagli Stati Uniti. L'articolo si concentra principalmente sull'analisi dei difetti che un'approccio come quello dell'UE potrebbe portare. Secondo l'autore, il lavoro dell'HLEG, un gruppo di esperti sull'IA, presenta tre principali limitazioni. La prima è che, nel corso degli ultimi anni, l'uso della parola 'IA' è diventato sempre più ambiguo e generale, venendo addirittura utilizzato in contesti errati. La seconda limitazione su cui l'articolo si è soffermato riguarda una proposta per la creazione di cattedre etiche, inefficenti secondo l'autore. Infatti, il problema dell'uso non etico della tecnologia si riscontra nei modelli di business, soprattutto da parte dei giganti tecnologici, i quali tendono ad ignorare le preoccupazioni e gli effetti esterni che producono. Infine, come ultima problematica, secondo Veale, l'IA applicata a infrastrutture preesistenti cambia l'equilibrio di potere. Basti pensare all'applicazione della visione artificiale alle telecamere, che hanno permesso di ottenere una sorveglianza costante. Come metafora, l'autore afferma che l'approccio dell'UE, pur volendo costruire una città etica per l'IA, rischia di concentrarsi solamente sulle decorazioni degli edifici (linee guida),

ignorando le sue fondamenta (infrastrutture dei dati) e le sue tubature (modelli di business), che invece rimangono poco controllate.

È interessante analizzare meglio anche l'approccio adottato dagli Stati Uniti, evidenziando i suoi pregi e le sue limitazioni. La visione statunitense è articolata nel documento "Blueprint for an AI Bill of Rights: Making Automated Systems Work for the American People". L'obiettivo principale di questo documento è affrontare l'uso della tecnologia e dei sistemi automatizzati, limitando l'accesso a risorse o servizi critici. Tuttavia, si riconosce che tali sistemi hanno numerosi potenziali per migliorare la vita di tutti. Nel dettaglio, il blueprint articola cinque principi che possono essere intesi come linee guida. La prima riguarda i sistemi sicuri ed efficaci (safe and effective systems), secondo cui i sistemi di sicurezza dovrebbero essere sviluppati consultando diversi esperti per identificare eventuali rischi. La seconda riguarda la protezione contro la discriminazione algoritmica (Algorithmic Discrimination Protections). Il documento afferma che tutti dovrebbero essere protetti dalla eventuale discriminazione causata dagli algoritmi, i quali potrebbero sfavorire determinate persone in base all'etnia, al sesso, alla disabilità... Il terzo punto chiave è dedicato alla privacy dei dati (Data Privacy), dove si afferma che si dovrebbe avere il controllo su come i propri dati vengano utilizzati, specialmente per quanto riguarda i dati sensibili che riguardano aspetti delicati, come la salute o la fedina penale. Come quarto punto, vi è la notifica e spiegazione (Notice and explanation), che afferma che bisogna sapere che un sistema automatizzato viene utilizzato e, nel caso, le spiegazioni di un eventuale risultato devono essere chiare e accessibili sia per l'utente sia per gli operatori. Infine, come ultimo punto, ci sono le alternative umane (Human alternatives). In quest'ultimo punto si afferma che si dovrebbe poter rinunciare ai sistemi automatizzati a favore di un'alternativa umana, soprattutto negli ambiti sensibili, come quelli che riguardano la salute o la giustizia penale. Tuttavia, il documento è una semplice guida etica e, quindi, non è giuridicamente vincolante, non può essere utilizzato per ottenere alcun tipo di beneficio e, soprattutto, non vi è alcun obbligo di attenersi alle sue indicazioni.

In sintesi, si può affermare che gli approcci dell'UE e degli Stati Uniti alla regolamentazione dell'IA siano diversi. L'UE, con l'AI Act, cerca di tutelare i diritti fondamentali, rischiando però di frenare l'innovazione. Al contrario, gli USA adottano un approccio flessibile e orientato al mercato, a discapito di una maggiore protezione per i cittadini. Si può quindi dire che la sfida rimane bilanciare il progresso tecnologico e salvaguardare l'etica.

1.3 Metodologie computazionali per l'analisi del discorso online

Topic modeling

Il Topic Modeling è una tecnica di machine learning non supervisionato che rientra nel campo del NLP. Il suo scopo è quello di analizzare un'insieme di documenti e scoprire automaticamente i principali topic latenti di ciascuno di essi. Con la nascita di siti web, blog e grandi testate giornalistiche, diventa sempre più importante la necessità di tecniche automatiche per organizzare, cercare, indicizzare e sfogliare collezioni di documenti. Si ipotizza di avere 10.000 articoli di notizie. Un modello di Topic Modeling potrebbe raggrupparli specificando i principali argomenti trattati,

come il topic 'economia' con parole chiave mercato, borsa, banca, inflazione, oppure il topic 'tecnologia' con parole chiave quali intelligenza, dati, software...

I modelli più tradizionali sono quelli basati principalmente sulla frequenza delle parole. Storicamente, il modello Latent Dirichlet Allocation (LDA) è stato il pilastro fondamentale nel campo del Topic Modeling e del Text Mining. LDA è un modello generativo probabilistico basato sull'idea che i documenti siano una miscela di argomenti e che ogni argomento sia una miscela di parole. L'algoritmo LDA si divide principalmente in quattro fasi distinte. La prima è la preparazione nella quale si decide quanti k argomenti trovare. Nella fase successiva, l'algoritmo assegna a ogni parola uno dei k argomenti. Segue la fase di miglioramento, nella quale viene analizzata ogni parola e successivamente l'algoritmo si pone due domande. Con la prima cerca di capire quanto sia popolare l'argomento scelto nel documento che sta venendo analizzato. Con la seconda domanda, invece, cerca di capire quanto sia popolare la parola nel topic analizzato, considerando tutti i documenti. L'ultimo passaggio consiste nella ripetizione della terza fase più volte al fine di migliorare le assegnazioni. Tuttavia, l'algoritmo LDA presenta tre importanti limitazioni. La prima è che il numero di topic da ricercare deve essere fissato in anticipo. La seconda limitazione è che tale modello non riesce a cogliere il contesto e il significato semantico delle parole. Infine, non è in grado di cogliere le relazioni tra i vari topic.

La ricerca si è quindi mossa verso l'uso di modelli che sfruttano i word embedding contestuali, più precisamente rappresentazioni numeriche delle parole che permettono di catturare il loro significato in base al contesto in cui esse appaiono. Uno dei modelli più importanti è il BERTopic, che estende l'approccio di trattare la modellazione dei topic come un compito di clustering. Il processo BERTopic si articola in tre passaggi fondamentali e indipendenti. Con la prima fase si punta a una rappresentazione vettoriale. Più precisamente, si procede a convertire ogni documento in vettori numerici che ne rappresentano anche il significato semantico. Quindi, i documenti con significati semantici simili avranno vettori vicini nello spazio vettoriale. Successivamente, il secondo passaggio si occupa di clusterizzare i documenti. Attraverso algoritmi di clustering, i documenti vengono raggruppati, in questa maniera, ogni cluster rappresenta un argomento. Infine, vi è la rappresentazione dei vari topic. In quest'ultima fase, vengono analizzate le parole all'interno di ogni topic e successivamente vengono estratte quelle che rappresentano al meglio l'argomento. Al fine di valutare i vari topic esistono varie metriche, tra cui la più importante è la coerenza dei topic (Topic Coherence), che misura quanto le parole chiave di un topic siano semanticamente correlate tra loro. Si può affermare che il BERTopic è uno strumento più efficace rispetto ai modelli tradizionali, principalmente per due ragioni. A differenza dell'LDA, il BERTopic determina in maniera automatica il numero ottimale di topic, rendendolo ideale. Inoltre, sfruttare modelli come BERT per creare embedding permette di cogliere il significato delle parole nel loro contesto, consentendo di inserire nello stesso topic documenti che non condividono le stesse parole chiave. Come per tutti i modelli, anche il BERTopic presenta delle limitazioni. Sicuramente, una di queste è il costo computazionale di utilizzare strumenti come questi. Inoltre, il problema più importante è che questo strumento si basa sull'assunzione che ogni documento contenga un solo argomento, quando, nella realtà, possono esserci più argomenti. Tuttavia, BERTopic offre meccanismi utili per superare questa limitazione. È infatti possibile calcolare le distribuzioni di probabilità dei topic per ciascun documento. In questa maniera, anche se il docu-

mento viene assegnato ad un determinato topic, si può comunque analizzare la sua affinità con gli altri topic ciò permette quindi di avere una visione più chiara.

Explainable Ai

L'Explainable AI (XAI) è un approccio che mira a rendere trasparenti e comprensibili i processi decisionali dei modelli di intelligenza artificiale. A differenza dei modelli black box, che producono risultati senza spiegare come siano arrivati, la XAI fornisce spiegazioni comprensibili, consentendo agli utenti di fidarsi dei risultati, verificarne l'affidabilità e conformarsi alle normative.

Quando si parla di questo campo di ricerca, è fondamentale citare il libro di Molnar "Interpretable Machine Learning: A Guide for Making Black Box Models Explainable" pubblicato nel 2020. L'autore, in questo libro, vuole dare rilievo ad un problema fondamentale che deriva dal fatto che spesso una predizione accurata non basta, specialmente quando si parla di determinati ambiti, come quelli sociali. Infatti, spesso in questi ambiti l'obiettivo non è unicamente quello di prevedere in maniera ottimale il risultato, ma è anche quello di comprendere i meccanismi che ci portano a tale risultato. Ad esempio, se si parla di raccomandazioni di film, è necessario conoscere solamente il risultato, invece, se si parla di prestiti bancari, allora bisogna scavare più a fondo e capire le motivazioni della previsione. Nasce qui il dilemma dell'interpretabilità e della spiegabilità. Secondo Molnar, si parla di interpretabilità quando una persona è in grado di comprendere il comportamento di un modello, mentre per spiegabilità si intende la capacità di fornire spiegazioni locali per le singole previsioni. Inoltre, il libro presenta anche il problema dei black box gia introdotto nella Subsubsection 1.2 riguardante l'etica, la sicurezza e i rischi. Nel libro, tali modelli vengono descritti come sistemi che non rivelano i loro meccanismi interni e che non possono essere compresi esaminando i parametri. Secondo Molnar, ci sono diverse ragioni principali per cui l'interpretabilità dei black box models è ritenuta fondamentale. Sicuramente, uno dei problemi è il rilevamento del bias e il fatto che spesso l'interpretabilità sia essenziale come strumento di debugging. Inoltre, come gia anticipato, l'interpretabilità permette di aumentare l'accettazione sociale. Per le persone, è più facile fidarsi di sistemi che permettono di spiegare le decisioni prese rispetto a modelli black box. Inoltre, anche per eventuali scoperte scientifiche, l'utilizzo di questi modelli potrebbe risultare incompleto poiché privo di chiarimenti.

L'utilizzo dei modelli black box ha portato allo sviluppo dell'Explainable AI (XAI). Il concetto alla base della XAI è quello di integrare o affiancare modelli già esistenti per estrarre informazioni che permettano di chiarire il loro comportamento. L'Explainable AI è utilizzata principalmente in tre aspetti. Il primo è quello della trasparenza, intesa come la capacità di comprendere il meccanismo del modello. Il secondo è quello di interpretabilità, che può essere globale, ovvero quando si vuole fornire una spiegazione generale sul processo decisionale di un modello. Un esempio è la feature importance, che misura l'impatto delle diverse variabili. In alternativa, l'interpretabilità può essere locale, in questo caso, fornisce una spiegazione limitata a una singola istanza oppure a un piccolo gruppo di istanze simili. Un esempio è il plain-fact explanation che illustra le cause dirette o i fattori principali che hanno portato il modello a produrre una determinata decisione. Infine, l'ultimo aspetto è quello della tracciabilità, ovvero la capacità di seguire un percorso logico che ha portato il modello a una determinata soluzione.

Uno degli approcci più diffusi nell'ambito della XAI è SHAP (SHapley Additive exPlanations), introdotto da Lundberg e Lee nel paper del 2017, "A Unified Approach to Interpreting Model Predictions". L'importanza dello SHAP è data dall'unificazione di diversi metodi di spiegazione gia esistenti. Più precisamente, si intendono i valori di Shapley, che derivano dalla teoria dei giochi cooperativi. Nello specifico, i valori di Shapley forniscono un metodo per distribuire equamente il guadagno tra i giocatori. La predizione di un modello è ritenuta come il suo guadagno, le features sono invece i giocatori che collaborano per ottenere quel guadagno. Infine, i valori SHAP calcolano come distribuire in modo equo il guadagno tra i vari giocatori, quindi il contributo alla previsione dato dalle varie features. Proprio grazie a queste solide basi, SHAP garantisce tre proprietà fondamentali. La prima è l'accuratezza locale, secondo cui la somma delle attribuzioni delle singole feature è uguale all'output del modello per quella specifica istanza. La seconda è la consistenza, che assicura che se il contributo di una feature in un modello aumenta o rimane invariato, il suo valore SHAP non può diminuire. Infine, la mancanza (Missingness) stabilisce che alle feature mancanti in un'istanza venga attribuito un impatto nullo.

L'analisi della percezione pubblica è un problema sociale molto complesso e l'utilizzo di metodi come la XAI diventa quindi essenziale. Nello specifico, SHAP verrà utilizzato per interpretare i risultati del modello predittivo dell'engagement al fine di identificare non solo quali sono i fattori più importanti, ma anche in che modo essi influenzano il risultato, permettendo di avere una comprensione più profonda.

1.4 Sintesi e posizionamento della Ricerca

Con l'analisi dello stato dell'arte, è stato possibile dimostrare un quadro generale della ricerca e della sua rapida evoluzione. Si è dimostrata l'importanza della Sentiment Analysis, evoluta fino ad una classificazione delle emozioni specifiche, tramite esempi concreti per monitorare l'opinione pubblica su piattaforme digitali come Twitter o Reddit. Nello studio sono stati analizzati anche altri strumenti molto utili ai fini di analizzare la percezione pubblica, uno tra questi è il Topic Modeling, che permette di mappare i temi centrali del dibattito. Infine, è emersa l'importanza di utilizzare approcci esplicativi che sottolineano la necessità di comprendere i meccanismi sottostanti, come l'Explainable AI.

L'obiettivo della tesi è costruire uno schema analitico che non si limiti a descrivere separatamente i temi e le emozioni del dibattito, ma che sfrutti la combinazione di questi strumenti per indagare quali fattori siano associati all'engagement e all'influenza delle diverse opinioni.

2 Metodologie

2.1 Fonte dei dati e metodo di raccolta

La piattaforma Reddit

Nello studio che viene svolto, la piattaforma social dalla quale sono stati raccolti i dati per l'analisi della percezione pubblica è Reddit. Reddit è un social nato nel 2005 e, nonostante sia una piattaforma generale contenente discussioni di ogni tipo, nel corso degli anni ha ottenuto un'ottima reputazione nei campi scientifici, tecnologici e informatici. È stato fondamentale comprendere al meglio come funzionasse tale social. Più precisamente, Reddit si basa su un sistema di community tematiche chiamate "subreddit". Attraverso queste community avvengono discussioni tra i vari utenti, i quali possono pubblicare e interagire tra loro tramite diversi tipi di contenuti, dai semplici testi fino ai link, alle immagini o ai video. Una caratteristica interessante da tenere in considerazione è che gli utenti operano tramite username, ciò permette di rimanere nell'anonimato e, di conseguenza, proprio grazie all'anonimato, le discussioni presenti su questo social sono più realistiche, soprattutto per quanto riguarda temi più sensibili.

Nonostante la presenza di numerosi social attraverso i quali poter svolgere queste analisi, Reddit è apparso l'opzione migliore sotto molteplici punti di vista. Prima di tutto, la struttura stessa di Reddit, divisa in vari subreddit, permette di raccogliere dati pertinenti all'argomento che si desidera analizzare. Inoltre, a differenza di numerose piattaforme social che limitano la lunghezza dei messaggi, Reddit non impone alcuna restrizione e ciò permette conversazioni più articolate che, a loro volta, colgono la complessità delle opinioni dei vari utenti, ottenendo cosi analisi più interessanti. In aggiunta, questa piattaforma permette non solo di ottenere i commenti dei diversi post, ma consente anche di ricevere informazioni aggiuntive. Infatti, per i post è stato possibile ottenere informazioni come lo score, l'upvote ratio, il numero dei commenti e la data di creazione del post, mentre per i commenti è stato possibile, anche in questo caso, ottenere lo score o il nome dell'autore del commento. Infine, un ultimo aspetto che bisogna tenere in considerazione è che Reddit offre un'API per la raccolta dei suoi dati, rendendo il lavoro, da un punto di vista computazionale, più rapido e comprensibile.

Il Subreddit Futurology

La raccolta dei dati di questo studio è avvenuta dal subreddit r/Futurology. Questa community è dedicata allo studio del futuro e, più precisamente, si occupa di temi come l'intelligenza artificiale, l'energia, lo spazio, la robotica... La scelta di r/Futurology è stata fondamentale per la rilevanza degli argomenti trattati in questo studio. Tuttavia, una fondamentale premessa che va fatta è che tale subreddit potrebbe non essere rappresentativo della popolazione generale. Come è stato anticipato, Reddit è diventato, nel corso degli anni, un social network in cui sempre più esperti si ritrovano per discutere delle varie tematiche. Quindi, è probabile che gli utenti di questo subreddit siano persone informate sulle nuove tecnologie e possano creare discussioni tecniche. Infine, un ultima caratteristica interessante di questa community è che molti post si basano principalmente su articoli di fonti esterne, come riviste scientifiche o testate giornalistiche. Quindi, le discussioni che avvengo-

no partono da fonti che si possono ritenere fidate, mentre la sezione dei commenti diventa la parte contenente le informazioni più interessanti.

Strumenti e procedura di raccolta

Per la raccolta dei dati, è stata utilizzata la libreria python PRAW (Python Reddit API Wrapper), uno strumento che permette di interagire in maniera semplice, rapida e diretta con l'API ufficiale di Reddit. Tuttavia, per garantire che ogni dato raccolto fosse pertinente allo studio svolto, è stato opportuno, prima di tutto, stabilire una 'AI Core Query', più precisamente, una stringa contenente tutti gli argomenti fondamentali per l'analisi delle discussioni relative all'intelligenza artificiale. Di seguito la AI Core Query:

```
"AGI" OR "general intelligence" OR "GPT" OR "deep learning"
OR "neural network" OR "AI"
```

Successivamente, questa 'AI Core Query' è stata unita a cinque macrotemi di interesse tramite l'operatore `AND`. Questo permetteva che i risultati fossero collegati sia al tema dell'IA, sia al tema specifico indagato. Più precisamente, i temi chiave sono:

AGI e sviluppo tecnologico:`AI Core Query`
Regolamentazione e IA: `("AI Act" OR "regulation" OR "policy" OR "law")`
Impatto sul lavoro e IA: `("jobs" OR "employment" OR "workforce" OR ")`
Sicurezza e rischi e IA: `("safety" OR "risk" OR "existential" OR "danger")`
Etica e IA: `("ethics" OR "ethical" OR "bias" OR "fairness" OR "moral")`

Inoltre, per la raccolta dei dati, sono stati utilizzati alcuni filtri al fine di migliorare la qualità dei dati. Più precisamente, è stato usato un filtro temporale che permette di considerare solo i contenuti pubblicati nell'ultimo anno, consentendo di ottenere analisi più recenti ed attuali. Successivamente, i risultati sono stati ordinati in base al punteggio (score), in modo tale che apparissero come primi quelli che hanno generato maggiore interesse all'interno del subreddit. Infine, per ogni categoria tematica, sono stati estratti solamente i primi 50 post più rilevanti.

Questa procedura ha permesso di ottenere 250 post e 57.887 commenti.

2.2 Costruzione e preprocesso del testo

Pulizia del dataset

Una volta completata la raccolta dei dati grezzi, è stata necessaria una fase di pulizia. Prima di tutto, i dati dei post e dei commenti erano stati raccolti in due dataset differenti, quindi, è stato opportuno unirli utilizzando il 'postid' come chiave.

Successivamente, sono stati rimossi dallo studio tutti i post duplicati. Infatti, nella raccolta dei dati, è accaduto che un post potesse essere rilevante per più argomenti, e ciò comportava la sua presenza in più macrotemi. Più precisamente, i duplicati presenti sono 41. In aggiunta a questo passaggio, sono stati analizzati a mano i restanti titoli per osservare se fossero coerenti con lo studio che si intende portare avanti. In questo caso, si è notato che circa 28 titoli di post non erano pertinenti e quindi, anche in questo caso, sono stati rimossi. Quindi si è passati da 250 post a 181 e da 57.887 commenti a 52.139.

Infine, un ultimo passaggio fondamentale è stato quello relativo ai valori mancanti. Durante una prima analisi esplorativa, il dataset ha rilevato la presenza di 3.051 valori mancanti. Questi valori mancanti erano tutti inerenti alla colonna 'author', che rappresenta lo username dell'utente che scrive il commento. Tuttavia, al posto di eliminare queste righe, che rappresentano informazioni che potrebbero essere utili all'analisi, si è scelto di imputare i valori nulli con la stringa 'author unknown' (autore sconosciuto). Questa decisione non solo ha permesso di mantenere i contenuti dei commenti, ma permette anche di offrire analisi molto interessanti legate ad essi.

Preprocesso del testo

Un altro passaggio fondamentale, prima di procedere con le analisi testuali, è stato quello di creare un pre-processing per la colonna 'body', una variabile che si riferisce ai commenti di Reddit. Più precisamente, sono stati effettuati tre passaggi ben distinti che hanno portato a ottenere una variabile più pulita ed ottimale per le analisi.

1. La conversione del testo in minuscolo. Il primo passaggio è stata la trasformazione di tutti i commenti in minuscolo, garantendo che la stessa parola venga trattata in modo uguale. Ad esempio, spesso nei commenti si possono trovare 'IA' o 'ia', ma entrambe esprimono lo stesso concetto e, per questo motivo, andrebbero trattate ugualmente.

2. Un altro passaggio fondamentale è stato quello di rimuovere ogni carattere di punteggiatura presente nei commenti. In aggiunta a ciò, se i commenti presentavano eventuali ritorni a capo, espressi in python con '`\n`', essi venivano sostituiti con un semplice spazio bianco. Ciò ha permesso non solo di ridurre il rumore all'interno di un testo, ma anche di concentrarsi maggiormente sui termini presenti.

3. Come terzo e ultimo passaggio nel preprocessing, c'è un ulteriore pulizia del testo. Più precisamente, tramite la libreria python spaCy e utilizzando il modello '`en_core_web_sm`', specializzato per la lingua inglese, è stato possibile eseguire più operazioni simultaneamente. Più precisamente, il testo è stato tokenizzato e a ogni token è stato sottoposto a un doppio controllo. Il primo era un controllo alfabetico che permetteva di mantenere nello studio unicamente caratteri alfabetici, eliminando quindi eventuali numeri o simboli residui. Il secondo controllo è stato quello delle stopword. Infatti, i singoli token, ovvero le singole parole, vengono confrontati con una lista predefinita di stopwords inglesi e, se una di queste parole è presente in essa, viene eliminata dallo studio. Questo metodo di controllo permette di eliminare le parole inglesi molto comuni, come 'the', 'is', 'a'... le quali non rappresentano informazioni aggiuntive per lo studio.

Al termine di questo preprocessing, si ottiene un testo pulito contenente unicamente parole in minuscolo, prive di simboli e prive delle stopwords. Quindi, si ha un testo pronto per eventuali analisi.

2.3 Analisi esplorativa dei dati - EDA

Statistiche descrittive

Un altra fase preliminare fondamentale è quella di un'analisi esplorativa dei dati (Exploratory Data Analysis - EDA), che ha lo scopo di comprendere le principali caratteristiche del dataset, identificare eventuali pattern e formulare le prime ipotesi che dovranno essere successivamente esaminate. Inizialmente, sono state calcolate le principali statistiche descrittive, come il numero di commenti, lo score medio e mediano, e la lunghezza media e mediana dei commenti per ciascuna delle cinque macro categorie di argomenti. Durante l'analisi esplorativa, sono stati effettuati anche numerosi altri processi, come:

- un'ispezione preliminare per analizzare la tipologia di ciascuna variabile presente, quindi, se fossero 'object', 'int64' o 'float64. Questo passaggio è fondamentale per le analisi successive, ad esempio per la creazione dei modelli di machine learning, dove le variabili testuali verranno imputate.

- Uno studio della varianza per tutte le colonne ha riscontrato che la colonna 'SubReddit' aveva una varianza pari a 0, indicando che tutti i valori al suo interno erano identici. Per tale motivo, è stato opportuno rimuovere quella variabile dallo studio.

- La creazione di due grafici con lo scopo di comprendere meglio i nostri dati. Più precisamente, il primo aveva lo scopo di raffigurare la distribuzione delle principali variabili numeriche. Il secondo, invece, è un grafico che rappresenta la matrice di correlazione utilizzando il coefficiente di pearson, con lo scopo di scoprire se ci siano relazioni lineari tra le variabili numeriche.

- Un ultima analisi è quella riguardante l'analisi temporale basata sulla pubblicazione dei commenti. L'obiettivo in questo caso era scoprire se eventuali aumenti dell'attività su Reddit fossero legati a specifici eventi inerenti al campo dell'IA.

Introduzione al text mining

Per analizzare il contenuto del testo, sono state utilizzate diverse tecniche di text mining con l'obiettivo di identificare dei pattern. Tra le prime tecniche utilizzate vi è sicuramente quella riguardante l'analisi delle frequenze per individuare i termini più usati. Tuttavia, è stata necessaria, ai fini di una comprensione migliore, l'analisi dei bigrammi, sequenza di due parole, e dei trigrammi, sequenza di tre parole. I risultati di queste analisi sono stati successivamente visualizzati tramite grafici, come grafici a barre o word cloud.

2.4 Selezione dei modelli per la sentiment analysis

Sentiment Analysis - SA

Il primo obiettivo è stato quello di identificare un modello che classificasse il sentiment come positivo, negativo o neutro. Al fine di utilizzare un modello competitivo, è stato impiegato un dataset reperibile su Kaggle chiamato 'Twitter and Reddit

Sentimental Analysis Dataset'. Più nello specifico, è stata utilizzata unicamente la parte relativa ai commenti di Reddit, costituita da 36.801 osservazioni, gia etichettate. Inoltre, per garantire una maggiore coerenza con lo studio, è stato applicato il medesimo preprocessamento utilizzato nella tesi per la pulizia del testo. Successivamente, sono stati utilizzati e messi a confronto otto diversi modelli disponibili sulla piattaforma Hugging Face, testandone le capacità predittive. I risultati hanno evidenziato una notevole variabilità nelle performance. Di seguito è riportata una tabella che riassume i risultati.

Modello	Valore (%)
Modello 1	49.61
Modello 2	31.47
Modello 3	37.12
Modello 4	43.72
Modello 5	50.34
Modello 6	46.55
Modello 7	75.94
Modello 8	51.73

Tabella 2.1: Percentuali per modello

Il modello 7 (akshataupadhye/finetuning-sentiment-model-reddit-data) è quello con risultati nettamente superiori, con un'accuratezza del 75,94%. Il modello in questione è una versione ottimizzata di DistilBERT, addestrata specificamente su dati provenienti da Reddit. Questo modello ha dimostrato una capacità superiore rispetto agli altri modelli, addestrati invece in generale per i social media o specificamente per twitter.

Una volta selezionato il modello 7, è stata condotta un ulteriore verifica sui dati che verranno utilizzati nello studio. Più precisamente, è stato estratto un campione casuale di 100 commenti, etichettato manualmente, e successivamente è stato utilizzato il modello migliore per confrontare le previsioni. Tuttavia, a differenza di quanto ci si potesse aspettare, il modello ha ottenuto un'accuratezza del 54%, troppo bassa per poter procedere. Questo calo dell'accuracy può essere dettato dal complesso linguaggio informale utilizzato sui social media (slang, abbreviazioni non standard, ironia, ...), che rende difficile per un singolo modello l'interpretazione corretta dei risultati.

Come prima strategia alternativa ai fini di migliorare i risultati, si è deciso di utilizzare modelli BERT per generare gli embeddings nel dataset e successivamente procedere all'applicazione di classificatori di machine learning per predire il sentiment finale. Nello specifico, sono stati ottenuti i seguenti risultati:

- Random Forest: 0.6331
- SVM: 0.6700
- Logistic Regression: 0.6751

Tra i tre modelli selezionati, logistic regression è quello con le migliori metriche e, come gia fatto precedentemente, per un'ulteriore verifica viene testato il modello sul

campione di 100 osservazioni etichettate manualmente. Purtroppo, anche in questo specifico caso si evidenzia una drastica diminuzione dell'accuratezza, scesa dal 54% al 36%.

Un'ulteriore alternativa è stata costruire un modello ensemble, aggregando i quattro migliori modelli (modelli 1, 5, 7 e 8). Il metodo non si basa su una semplice 'majority voting', bensì su una media ponderata. Più precisamente, ad ogni modello viene assegnato un peso proporzionale alla sua accuratezza nel dataset di prova e successivamente il funzionamento di questo modello ensemble si suddivide in tre fasi:

1. Ogni singolo modello genera una predizione numerica (-1, 0 e 1).
2. Viene calcolata la media ponderata delle previsioni.
3. Il punteggio finale viene classificato in base a delle soglie. Se il valore è superiore a 0,25 allora il sentiment è positivo, se è inferiore a -0,25 allora è negativo e se ricade nell'intervallo tra -0,25 e 0,25 allora il sentiment è neutro.

Sottoponendo anche quest'ultimo modello al nostro campione, si è registrato un'accuratezza del 70%, risultato nettamente superiore a quello dei modelli precedenti e accettabile per proseguire con lo studio.

Textual Emotion Analysis - TEA

Il secondo obiettivo mirava invece a superare la semplice distinzione tra Positivo, Negativo e Neutro, e puntava a identificare le emozioni specifiche. A differenza del modello utilizzato precedentemente, non è stato possibile trovare un dataset di commenti Reddit gia etichettati per le emozioni che fosse abbastanza affidabile. Per tale motivo, è stato scelto direttamente un modello diffuso e robusto da hugging face, più precisamente, il modello si chiama: j-hartmann/emotion-english-distilroberta-base.

Si tratta di una versione ottimizzata di DistilRoBERTa-base ed è un modello che si basa sulle teorie di Ekman; quindi è in grado di riconoscere 6 emozioni distinte, più 'neutro':

1. Rabbia
2. Disgusto
3. Paura
4. Gioia
5. Tristezza
6. Sorpresa
7. Neutro

Tuttavia, ci sono due considerazioni da tenere in conto che supportano la scelta di questo modello rispetto ad altri modelli. La prima è che il modello di j-hartmann è stato addestrato su 6 dataset differenti, che includono dialoghi, twett e testi narrativi, rendendolo particolarmente robusto e adatto allo studio che si intende fare. La seconda è che, nonostante esso presenti un'accuracy del 66%, che a prima vista

può sembrare poco elevata, la probabilità di indovinare il sentiment andando a caso sarebbe appena del 14%, quindi il modello indica una capacità solida e superiore a questa casualità.

2.5 Modello di Topic Modeling

Scelta del modello

Come gia approfondito nel capitolo 1.3 dedicato allo Stato dell'Arte, si è evidenziato come i modelli basati su Transformer offrano prestazioni migliori rispetto a quelli tradizionali come la LDA. Per questo motivo, è stato selezionato il modello BERTopic.

A differenza dell'analisi dei sentimenti, il Topic Modeling non è stato applicato ai commenti di Reddit, bensì ai titoli dei post. Questa scelta è avvenuta con lo scopo di identificare i temi della discussione, che emergono con maggiore sintesi e chiarezza nei titoli rispetto ai commenti. Nell'utilizzo del modello BERTopic, sono stati fissati alcuni parametri per adattarsi in modo ottimale ai titoli.

1. La conversione dei titoli in vettori numerici è stata effettuata tramite il modello 'all-mpnet-base-v2'. Questo modello permette di catturare i significati semantici delle frasi, riuscendo a distinguere i titoli che utilizzano parole simili, ma con significati diversi.

2. Per raggruppare i titoli, è stato utilizzato l'algoritmo 'HDBSCAN'. In questa fase, il parametro utilizzato è stato il `min_topic_size` impostato a 5, ciò significa che un cluster sarà considerato valido se contiene almeno 5 titoli di post

3. Un ultimo parametro fissato è stato `nr_topics` impostato su 'auto'. Questo parametro stabilisce un numero fisso di cluster da creare. Impostare `nr_topics` su 'auto' indica che non esiste un numero prestabilito di cluster da creare, ma lascia questa scelta al modello stesso.

In totale, si sono ottenuti 7 topic, i quali saranno analizzati successivamente.

Titoli dei topic

È stato deciso di applicare il modello a tutti i titoli, senza suddividerli preventivamente nei diversi macro-argomenti. L'obiettivo era, infatti, permettere ai temi di aggregarsi anche tra di loro in base alle similarità semantiche e oggettive, evitando che le ipotesi di aggregazione formulate precedentemente potessero influenzare i cluster. Infine, per ogni cluster identificato sono state assegnate manualmente delle etichette che ne sintetizzano il contenuto.

2.6 Modello predittivo e di spiegabilità (XAI)

Definizione del problema

Nell'ultima parte si procede alla creazione di un modello di machine learning supervisionato. L'obiettivo non era solo prevedere il punteggio di un commento, ma

utilizzare il modello come indagine per studiare le variabili che influenzano maggiormente l'engagement del pubblico. La variabile target è 'score_comment', ovvero il punteggio tra upvotes e downvotes. Tuttavia, è importante sapere che tale variabile è fortemente asimmetrica, con una mediana di 2 e un valore massimo superiore a 15000. Quindi, spesso provare a calcolare il punteggio preciso di un commento di Reddit può essere quasi impossibile, in quanto i commenti sono imprevedibili. Il successo di un commento dipende da numerosi fattori, alcuni dei quali non sono presenti nello studio, come ad esempio l'eventuale timing esatto (primo commento o ultimo sotto un post), se qualcuno famoso risponde, se il post viene linkato altrove, e così via dicendo. Per tali ragioni, è stato deciso di trasformare il problema in una classificazione multiclasse, distinguendo tre fasce di popolarità, più precisamente:

1. Basso (low), con score tra 0 e 3.
2. Medio (Medium), con score tra 4 e 10.
3. Alto (high), con score superiore a 11.

Ai fini di ottenere un risultato il più preciso possibile, che sia anche in grado di spiegare quali siano le variabili che influenzano maggiormente l'engagement del pubblico, sono state considerate 15 variabili. Più precisamente:

1. Sono state utilizzate variabili relative al contesto del post originale, come lo score_post, UpVote_Ratio e Num_Comments.
2. Sono state utilizzate le metriche che riguardano il testo stesso, come word_count, che ne indica la lunghezza, o avg_word_count.
3. Sono stati utilizzati i risultati ottenuti dalle analisi precedenti, quali il Sentiment e l'emotion prevalente, trasformati in input numerici.
4. Sono state utilizzate le variabili che riportavano il momento della pubblicazione, che potrebbe aver inciso sulla visibilità. Sono variabili come l'ora, il giorno della settimana e il mese.

Quindi, sono state utilizzate anche numerose variabili categoriche, le quali sono state trasformate in variabili numeriche tramite Label Encoding. Infine, il dataset è stato suddiviso in un training set (80%) e un test set (20%), utilizzando un campionamento che permettesse di mantenere le proporzioni delle tre classi target, in quanto sbilanciate.

Scelta del modello

Per identificare l'algoritmo più performante, è stato condotto un confronto tra due modelli. Il primo è il Random Forest, un metodo che costruisce più alberi decisionali e aggrega i risultati per ridurre il rischio di overfitting. Il secondo è XGBoost, un metodo di boosting che costruisce alberi decisionali sequenzialmente, quindi, ogni nuovo modello cerca di correggere gli errori del precedente. Nella scelta del modello, è stata implementata una procedura di ottimizzazione degli iperparametri tramite il grid search con cross validation (5 fold). Questa tecnica consiste nel testare le diverse combinazioni dei parametri, dividendo precedentemente il dataset in 5 parti, e ognuna di queste parti verrà utilizzata come test per ogni combinazione possibile. Più precisamente, si ha:

1. Per il random forest, sono state testate 54 combinazioni diverse, quindi, sono stati creati un totale di 270 modelli. Tra i vari iperparametri analizzati ci sono il numero degli alberi decisionali da utilizzare (n_estimators), la profondità degli alberi decisionali (max_depth), quante osservazioni un nodo deve avere perchè esso venga suddiviso (min_samples_split), quanti elementi deve contenere un nodo per essere creato (min_samples_leaf) e infine il bilanciamento delle classi (class_weight)

2. Per XGBoost, sono state valutate 12 combinazioni, quindi, sono stati creati un totale di 60 modelli. In questo caso, tra i vari iperparametri, abbiamo il tasso di apprendimento (learning_rate), la profondità degli alberi (max_depth), il numero di alberi nel modello (n_estimators), la percentuale di variabili utilizzate per costruire ogni albero, la quale serve a ridurre l'overfitting (colsample_bytree) e infine la percentuale di osservazioni usate per addestrare ogni albero, anche questo per ridurre l'overfitting (subsample).

Metodologia di spiegabilità

Il modello Random forest è un modello black box complesso. Come gia citato nel capitolo dello stato dell'arte, l'accuratezza predittiva non è sempre sufficiente e, per una migliore interpretazione, è stato deciso di applicare il metodo SHAP. Più nello specifico, è stato utilizzato un'approccio chiamato 'TreeExplainer' e la sua analisi è stata suddivisa principalmente in tre livelli:

- Prima di tutto, vi è un'interpretabilità globale. Più precisamente, è stata creata una gerarchia delle variabili che influenzano maggiormente il modello tramite un summary bar plot, calcolando la media dei valori SHAP. Affinchè i risultati ottenuti fossero maggiormente robusti, è stato effettuato un confronto tra i valori SHAP e le Feature importance di random forest.

- Successivamente, per comprendere al meglio l'impatto delle variabili, sono stati generati i Beeswarm plots per ciascuna delle classi target. Questi grafici sono fondamentali perchè permettono di capire quanto una variabile è importante e come essa possa aiutare nella predizione.

- Infine, sono stati utilizzati dei grafici Waterfall plots per l'analisi dei singoli casi. Questi grafici permettono di comprendere meglio le decisioni che il modello prende per le singole osservazioni. Nel dettaglio, i modelli partono da una probabilità media e successivamente ogni variabile aggiunge o sottrae punti da tale probabilità. La somma finale di questi contributi ci darà una spiegazione dell'assegnazione del singolo commento a una determinata classe.

3 Esperimenti e risultati

3.1 Panoramica Descrittiva

Risultati dell'analisi descrittiva

Ai fini di avere una visione più chiara del dataset, sono state raccolte le principali statistiche per ogni macro categoria nelle tabelle sottostanti.

Macro-Categoria	Numero di Commenti	Score Medio	Score Mediano
AGI e Sviluppo Tecnologico	19255	40.51	3.0
Etica e AI	3462	6.40	1.0
Impatto sul Lavoro e AI	15313	26.08	2.0
Regolamentazione e AI	7284	18.64	2.0
Sicurezza e AI	6825	16.15	2.0

Tabella 3.1: Statistiche sui Commenti e sui Punteggi

Macro-Categoria	Lunghezza Media (caratteri)	Lunghezza Mediana (caratteri)
AGI e Sviluppo Tecnologico	254.66	153.0
Etica e AI	339.85	195.0
Impatto sul Lavoro e AI	285.56	176.0
Regolamentazione e AI	276.88	163.0
Sicurezza e AI	278.57	162.0

Tabella 3.2: Statistiche sulle Lunghezze dei Commenti

Le Tabelle 3.1 e 3.2 rivelano alcuni pattern interessanti. Prima di tutto, si può osservare dal numero di commenti che la categoria 'AGI e Sviluppo Tecnologico' è quella che contiene il maggior numero di essi. Inoltre, quest'area è rappresentata da uno score medio piuttosto alto, pari a 40,51, una volta e mezzo in più rispetto al secondo score medio più alto, rappresentato dalla categoria 'Impatto sul lavoro'. Nonostante anche lo score mediano di questa categoria appaia il più alto, considerando tutte le diverse aree, è possibile osservare un contrasto tra il valore medio e quello mediano. Infatti, lo score mediano è di appena 3, indicando una forte asimmetria positiva. Questo può essere la conseguenza della grande mole di commenti presenti in questa categoria, i quali possono portare a commenti virali, ottenendo quindi punteggi molto elevati.

Nonostante la categoria 'Etica e AI' sia quella meno discussa, con uno score medio (6,40) e uno score mediano (1.0) più bassi, è interessante notare come nella Tabella 3.2 quest'area presenti la lunghezza media e mediana dei commenti più elevata. La maggiore lunghezza potrebbe derivare dal fatto che i temi etici suscitano spesso un alto coinvolgimento personale, emotivo o speculativo.

Questa analisi preliminare ha mostrato un notevole squilibrio nel dataset, con un'area 'AGI e Sviluppo Tecnologico' che tende ad essere dominante rispetto alle

altre categorie più piccole. Ai fini di condurre un analisi più bilanciata, è parso opportuno un raggruppamento basato sulla coerenza tematica. Più precisamente, 'Impatto sul lavoro' e 'Regolamentazione' sono stati uniti in 'Impatto socio-economico e governance'. Entrambi i temi, infatti, tendono a riguardare le conseguenze dell'IA con cui le società e i governi devono fare i conti. Quindi, sia da un punto di vista economico (il lavoro) sia da un punto di vista legale e politico (governance). Invece, 'etica' è stata unita a 'sicurezza' e si è ottenuto 'Rischi, Etica e Sicurezza'. Questo tema tratta dei potenziali danni della tecnologia. Mentre l'etica affronta i principi morali del funzionamento dell'IA (come il bias), la sicurezza si occupa dei rischi operativi e di controllo.

Di seguito è riportata una tabella che riassume i risultati.

Macro-Topic	Numero di Commenti	Score Medio	Score Mediano
AGI e Sviluppo Tecnologico	19255	40.51	3.0
Impatto Socio-Economico e Governance	22597	23.68	2.0
Rischi, Etica e Sicurezza	10287	12.87	2.0

Tabella 3.3: Statistiche sui Commenti e sui Punteggi per Macro-Topic

Macro-Topic	Lunghezza Media (caratteri)	Lunghezza Mediana (caratteri)
AGI e Sviluppo Tecnologico	254.66	153.0
Impatto Socio-Economico e Governance	282.76	172.0
Rischi, Etica e Sicurezza	299.19	172.0

Tabella 3.4: Statistiche sulle Lunghezze dei Commenti per Macro-Topic

Il macro topic 'Impatto Socio-Economico e Governance' diventa quello più voluminoso per numero di commenti, mentre 'AGI e Sviluppo Tecnologico' mantiene il suo primato negli score. Inoltre, si può notare come 'Rischi, Etica e Sicurezza' rimanga quello con i commenti mediamente più lunghi.

Come gia anticipato nel capitolo sul metodologie, sono stati effettuati anche numerosi altri processi. Uno di questi era l'ispezione per analizzare la tipologia delle diverse variabili. Per una comprensione più facile, viene proposto un grafico:

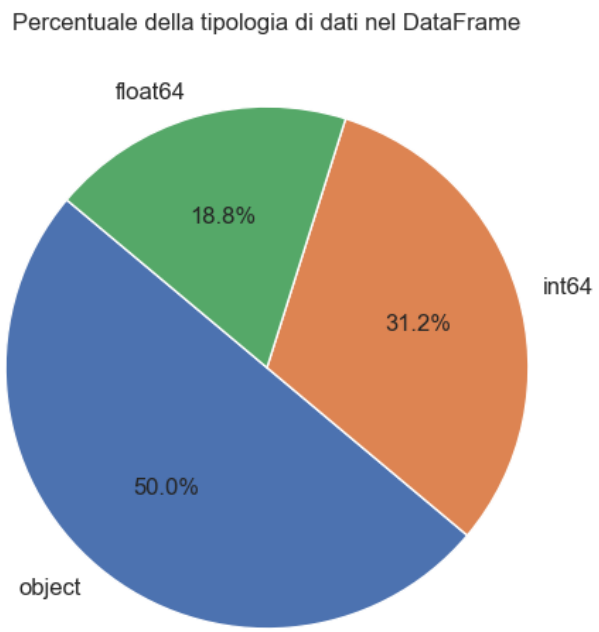

Figura 3.1: Tipologia degli elementi presenti nel DataFrame

Più precisamente, il dataset analizzato è composto da 16 variabili. Esaminando il grafico proposto, si può affermare che metà di queste variabili è numerica, mentre l'altra metà appartiene alla categoria 'object'. Successivamente, si procede con la creazione di due grafici che ci aiutano a comprendere meglio i nostri dati.

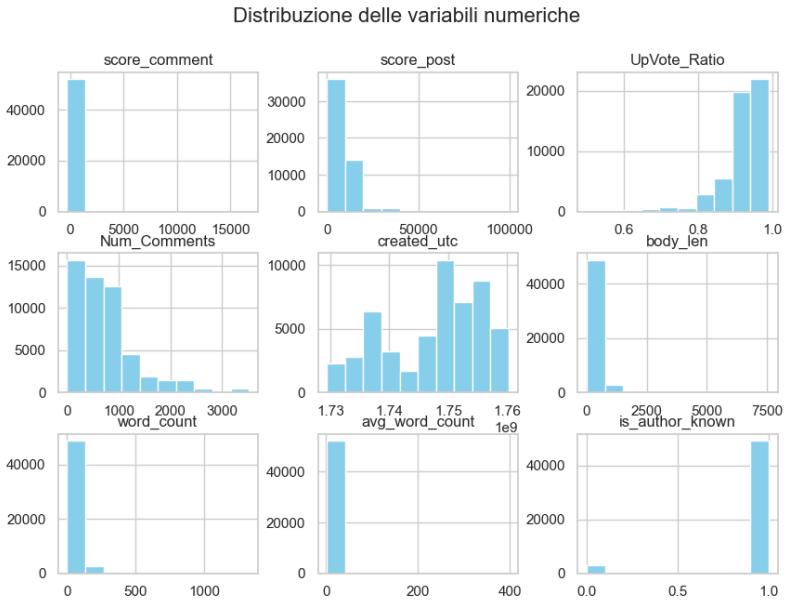

Figura 3.2: Distribuzione delle variabili numeriche nel dataset

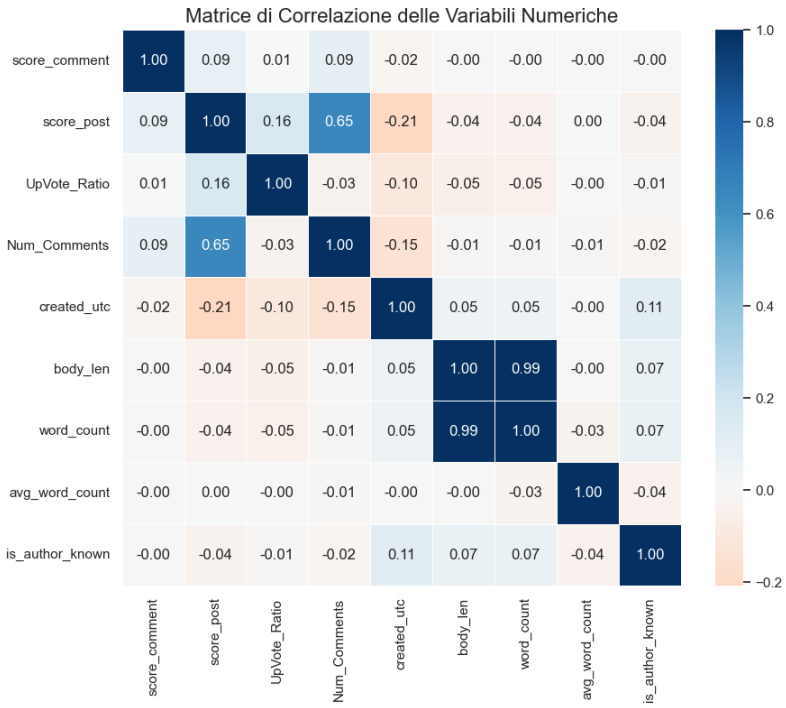

Figura 3.3: Matrice di correlazione delle variabili numeriche

La Figura 3.2 mostra gli istogrammi di nove variabili numeriche e rivela alcuni pattern:

- La maggior parte delle variabili legate all'engagement e ai contenuti dei commenti presentano una forte asimmetria positiva. Più precisamente, sono le variabili 'score_comment', 'score_post', 'Num_Comments', 'body_len', 'word_count' e 'avg_word_count'.

- La variabile 'UpVote_Ratio', mostra una distribuzione opposta, con un'asimmetria negativa. Infatti, la maggior parte dei valori di questa variabile si riscontrano nell'intervallo tra 0.8 e 1.0.

- La variabile 'is_author_known' è una variabile binaria, con valori pari a 0 o a 1. Il grafico mostra come la maggior parte dei valori di questa variabile sia pari a 1, indicando che, nella maggior parte delle osservazioni raccolte, l'autore è conosciuto.

- La variabile 'created_utc' non rappresenta in se una distribuzione, ma bensì una serie storica, evidenziando periodi di maggiore attività. Ai fine di una migliore analisi riguardo la serie storica, è stato creato un apposito grafico, che verrà analizzato successivamente.

Il secondo grafico proposto mostra la matrice di correlazione di Pearson tra le variabili numeriche. Un valore vicino a 1 nella Figura 3.3 indica una forte correlazione positiva, un valore vicino a -1 indica invece una correlazione negativa, mentre valori intorno a 0 indicano un'assenza di legame lineare. Dal grafico emerge che vi è principalmente un'assenza di forti correlazioni lineari tra le variabili. Fanno eccezione due casi:

- Si osserva che tra 'body_len' e 'word_count' esista una correlazione quasi perfetta, pari a 0,99. Tuttavia, questo è molto coerente con ciò che queste variabili spiegano, poichè la lunghezza di un testo è proporzionale al numero di parole che il testo contiene.

- Si osserva che tra 'score_post' e 'Num_Comments' vi sia una correlazione positiva moderata. Questo può significare che i post che ottengono punteggi più elevati tendono ad avere un numero maggiore di commenti.

Infine, per comprendere l'evoluzione della discussione nel tempo, è stato analizzato l'andamento temporale tramite la seguente figura:

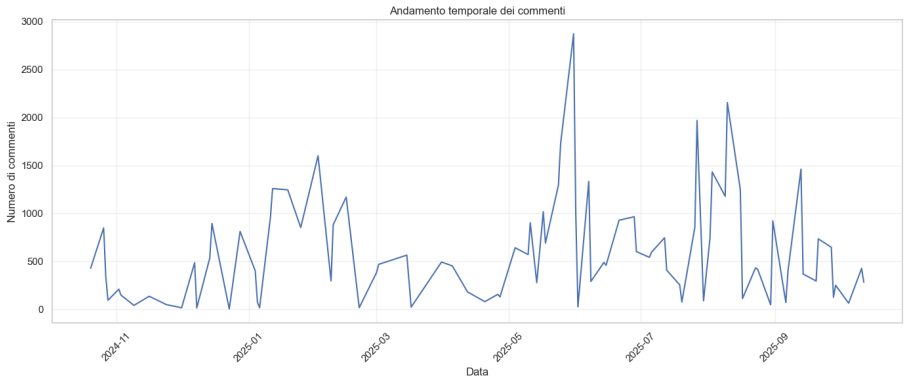

Figura 3.4: Andamento temporale dei commenti

Il grafico 3.4 mostra come la discussione non sia sempre costante, ma sia caratterizzata da periodi calmi alternati a picchi improvvisi. Il pattern ottenuto da questo grafico è spesso diffuso nelle conversazioni online, dove eventuali eventi esterni possono influenzare direttamente l'attività. Sono stati identificati principalmente cinque picchi di attività:

- Durante il mese di maggio si sono verificati due picchi. Il primo il 31 maggio 2025 con 2873 commenti, mentre il secondo il 25 maggio con 1726 commenti. Entrambi i picchi possono essere legati al 'Festival del lavoro 2025' tenuto nella seconda metà di maggio. Se, invece, consideriamo un livello più globale, potrebbe fare riferimento a qualche conferenza specifica.

- Il 10 agosto 2025, con 2156 commenti. Durante questo periodo, è stato ufficialmente lanciato il modello GPT-5 di OpenAI e, inoltre, sono entrate in vigore le prime norme operative dell'AI Act europeo.

- Il 27 luglio 2025, con 1969 commenti. Questo picco di commenti può essere legato alla pubblicazione dei risultati finanziari trimestrali da parte di grandi aziende tecnologiche. Durante queste presentazioni, spesso ci sono discussioni riguardanti le strategie di investimento nell'IA e le relative implicazioni.

- Il 2 febbraio 2025, con 1601 commenti. In questo periodo, alcune pratiche dell'AI Act europeo sono entrate pienamente in vigore.

Quindi, l'analisi temporale rafforza l'idea secondo cui il dibattito online sia un fenomeno guidato da eventi concreti.

Risultati del text mining

Per ottenere una comprensione riguardo al corpo dei commenti, è stato opportuno svolgere una parte di text mining, senza distinzioni tra i diversi macro argomenti.

Il primo passaggio fondamentale è stato lo studio delle frequenze dei singoli termini. Di seguito sono riportati due grafici che ci aiutano in questo studio.

Figura 3.5: WordCloud dei commenti

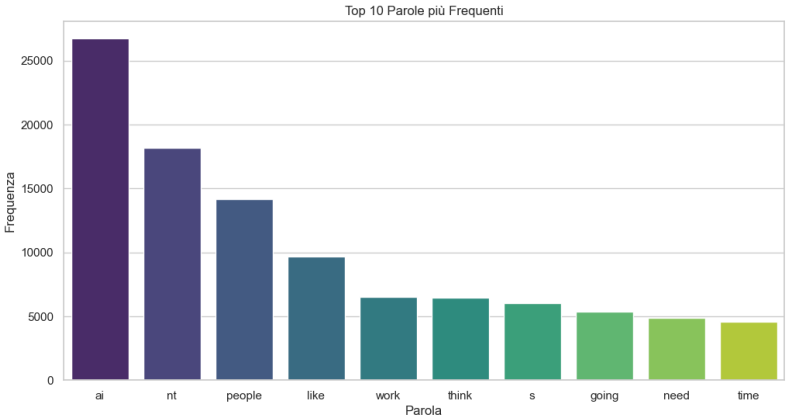

Figura 3.6: Top 10 parole più frequenti

Come illustrato dalla Word Cloud (Figura 3.5) e dal grafico delle parole più frequenti (Figura 3.6), il termine 'ai', come previsto, è dominante all'interno dei commenti. Accanto ad esso emergono parole come 'people', 'work', 'jobs', 'human' e 'world'. Si può ipotizzare che il focus della discussione non sia un dibattito puramente tecnico, ma piuttosto un dibattito incentrato sull'impatto umano e sociale della tecnologia. Altre parole frequenti sono 'think' e 'like', che rafforzano questa ipotesi di commenti poco tecnici, ma più orientati verso le opinioni personali degli utenti del social network. Da notare è la presenza di termini come 'nt' e 's' che derivano da un linguaggio informale inglese e che spesso sono il risultato di contrazioni comuni. Probabilmente 'nt' si riferisce al termine "don't" mentre 's' al termine "it's"

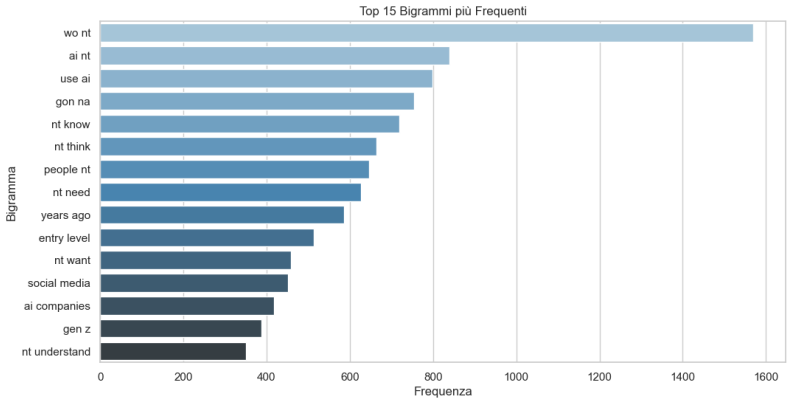

Figura 3.7: Bigrammi dei commenti

Un'analisi sicuramente più interessante avviene attraverso i bigrammi (Figura 3.7). Attraverso questo grafico, la natura del linguaggio informale diventa ancora più evidente. I bigrammi più comuni, infatti,sono 'wo nt' che non è altro che un'abbreviazione di "won't", 'ai nt' significa invece "ain't", mentre 'nt know' deriva da "don't know". Grazie a questo bigramma, non solo è stato evidenziato l'utilizzo delle abbreviazioni, fortemente diffuse nelle conversazioni online, ma anche che una parte del discorso è caratterizzata da dubbi, incertezze e negazioni. Accanto a questi bigrammi ve ne sono altri che permettono di delineare argomenti più specifici, come 'ai companies' o 'entry level'.

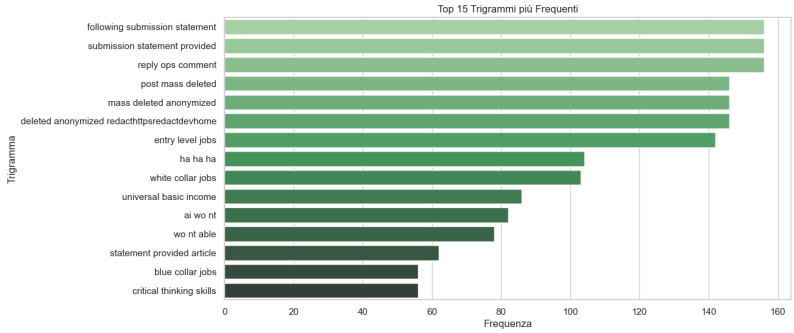

Figura 3.8: Trigrammi dei commenti

È stato quindi necessario l'utilizzo anche dei trigrammi (Figura 3.8) che offrono un quadro ancora più dettagliato. Anche in questo caso, si può affermare la presenza di rumore dovuto soprattutto a frasi generate dal sistema di Reddit come 'following submission statement' oppure 'post mass deleted'. Tuttavia, emergono concetti molto interessanti legati principalmente al mondo del lavoro, come 'entry level jobs', 'white collar jobs', 'blue collar jobs' e 'critical thinking skills'.

Si può quindi affermare che questa breve analisi testuale ha rilevato un discorso focalizzato sull'impatto umano dell'IA, caratterizzato da un linguaggio informale.

3.2 Analisi emotiva nel dibattito

Risultati della Sentiment Analysis

La Sentiment Analysis classifica ogni commento come positivo (1), negativo (-1) o neutro (0). Una volta che è stato assegnato un sentiment a tutti i commenti del dataset in studio, è stato possibile procedere con le analisi.

Distribuzione generale del dataset
La prima analisi proposta si basa sul conteggio assoluto dei commenti per ciascun tipo di sentiment.

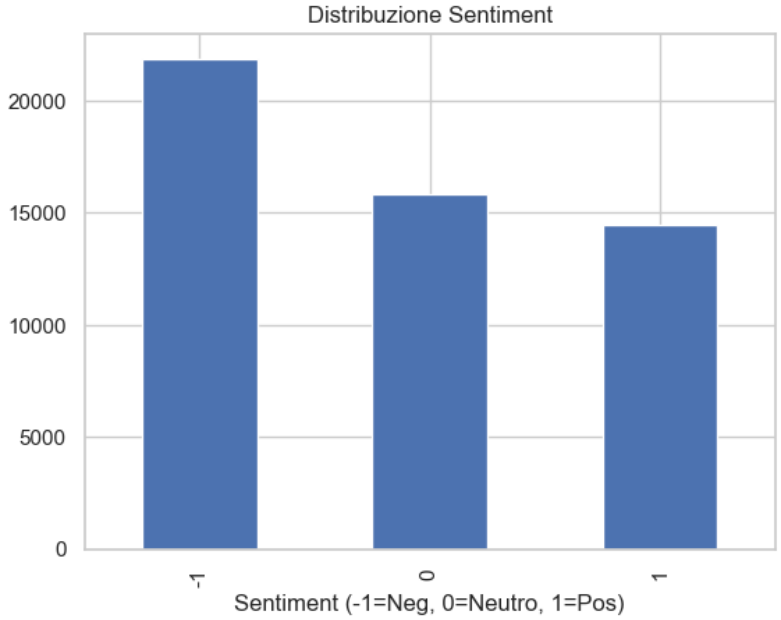

Figura 3.9: Distribuzione dei sentiment nei commenti

Più precisamente si ottiene:

- Sentiment negativo: 21.896 commenti.
- Sentiment neutro: 15.803 commenti.
- Sentiment positivo: 14.440 commenti.

Si può quindi dire che il sentiment più rappresentato all'interno di questo dataset è quello negativo. Tuttavia, vi è anche una grande porzione di commenti con sentiment positivo e neutro. Si può affermare che il dibattito pubblico non sia fortemente polarizzato, bensì si collochi in una zona intermedia, con una leggera visione pessimistica riguardante l'IA. Inoltre, la presenza numerosa di commenti neutri, potrebbe indicare principalmente commenti di forma più tecnica.

Relazione tra Sentiment e Engagement
Un aspetto cruciale nell'analisi del sentiment è comprendere se il sentiment possa influenzare la visibilità e il successo del commento stesso all'interno del post. Si osservi la seguente tabella:

Sentiment	Score Medio
-1	31.698621
0	29.259571
1	20.164889

Tabella 3.5: Score medio per classe di sentiment

La Tabella 3.5 dimostra come i commenti negativi ottengano, in media, punteggi più alti rispetto ai commenti positivi. Questo può significare che le critiche o i timori degli utenti tendono ad attirare maggiore attenzione rispetto ai commenti positivi. Ai fini di rafforzare questa ipotesi, sono state calcolate le correlazioni di pearson e di spearman tra il sentiment e gli score dei commenti e dei post. Si osservano le seguenti matrici:

	Sentiment	score_comment	score_post
Sentiment	1.000000	-0.019478	-0.031549
score_comment	-0.019478	1.000000	0.085433
score_post	-0.031549	0.085433	1.000000

Tabella 3.6: Matrice di correlazione di Pearson

	Sentiment	score_comment	score_post
Sentiment	1.000000	-0.028190	-0.035493
score_comment	-0.028190	1.000000	0.213071
score_post	-0.035493	0.213071	1.000000

Tabella 3.7: Matrice di correlazione di Spearman

I coefficienti di entrambe le matrici di correlazione sono vicini a zero. Si è quindi dimostrato che la polarità di un commento non è sufficiente per scoprire il suo engagement e viceversa. Si può quindi affermare che le dinamiche che determinano il successo o meno di un commento siano più complesse.

Sentiment medio nei post con una forte partecipazione
In questa parte si vuole studiare i post con il maggior numero di commenti, per valutare quale sia il sentiment medio nei post fortemente discussi.

Post ID	Sentiment Medio	Numero Commenti	Score Post
1h8h483	-0.318182	3523	99503
1jnqxqm	-0.111789	2599	8712
1maq7ut	-0.208925	2192	14073
1hzvcbd	-0.116667	1893	15040
1lmncmi	-0.173387	1872	15168

Tabella 3.8: Sentiment medio nei post con elevata partecipazione

I risultati mostrano come i post più discussi tendano ad avere un sentiment leggermente negativo. Questo indica che i post più discussi presentano un equilibrio di opinioni positive e negative, ma tendono ad essere leggermente più sfavorevoli. È interessante osservare le ipotesi formulate nell'analisi della matrice di correlazione (Figura 3.3). Più precisamente, i post con il maggior numero di commenti sono anche quelli con uno score post più elevato.

UpVoteRatio e Sentiment
Come ultima analisi, per la Sentiment Analysis, è stata esaminata la relazione tra UpVoteRatio e il sentiment dei commenti. Prima di procedere, è importante comprendere la metrica UpVoteRatio. Più precisamente, questa metrica è una percentuale di voti positivi ricevuti da un post. Il valore finale è compreso tra 0 e 1, e un risultato pari ad 1 indica che il post è composto solo da upvote, un valore pari a 0 indica la presenza di solo downvote, mentre un valore di 0,5 indica che metà dei voti sono positivi e l'altra metà sono negativi. Si può quindi dire che se il valore di questa metrica è basso, indica post controversi, viceversa, valori elevati indicano un post approvato dalla community. La tabella seguente raffigura i risultati ottenuti:

UpVote_Ratio	Sentiment
(0.5, 0.598]	0.049645
(0.598, 0.696]	0.009208
(0.696, 0.794]	-0.056987
(0.794, 0.892]	-0.093731
(0.892, 0.99]	-0.158138

Tabella 3.9: Controversia e Sentiment

Come si può notare dalla Tabella 3.9, i post meno controversi (UpVote Ratio alto) tendono a creare un dibattito lievemente polarizzato verso il sentiment negativo. Invece, i post che dividono maggiormente l'opinione pubblica, con valori UpVote Ratio bassi, tendono ad avere un sentiment medio neutro.

Risultati della Textual Emotion Analysis

Mentre la Sentiment Analysis mira a fornire una visione generale sulla polarità del dibattito, la Text Emotion Analysis mira a esplorare le singole emozioni: rabbia, gioia, paura, tristezza, sorpresa, disgusto e neutro.

Distribuzione generale del dataset
Come per la SA la prima analisi proposta si basa sul conteggio assoluto delle emozioni per ciascun commento.

Emozione	Conteggio	Percentuale (%)
neutral	19669	37.72
anger	8511	16.32
joy	6689	12.83
sadness	6338	12.16
surprise	6127	11.75
fear	4204	8.06
disgust	601	1.15

Tabella 3.10: Distribuzione delle emozioni

Osservando la Tabella 3.10 si può notare che l'emozione predominante è 'neutral', circa il 37,72% delle nostre osservazioni. Analizzando più a fondo le varie emozioni, si scopre che la più rappresentata è 'anger' con un 16,32%. Ciò significa che buona parte del dibattito è composta da forti disapprovazioni. A seguire, si hanno 'joy' con 12,83%, 'sadness' con 12,16%, 'surprise' con 11,75%, 'fear' con 8,06% e infine 'disgust' con 1,15%. Senza considerare l'emozione 'neutral', si può affermare che il panorama emotivo non è polarizzato da una singola emozione, ma tutte loro ricoprono un ruolo importante.

Emozioni per macro-categoria tematica
Interessante, è l'analisi della distribuzione delle emozioni suddivise per la macro categoria di appartenenza, come mostrato nella seguente tabella:

Emozione	AGI e Sviluppo	Impatto Socio-Economico e Governance	Etica e Sicurezza
neutral	38.53%	37.20%	37.38%
disgust	1.35%	1.10%	0.90%
anger	16.23%	15.80%	17.64%
surprise	11.53%	12.49%	10.53%
fear	6.78%	7.98%	10.64%
sadness	12.75%	12.56%	10.15%
joy	12.82%	12.87%	12.75%

Tabella 3.11: Distribuzione percentuale delle emozioni nei diversi macro-topic

La Tabella 3.11 mostra chiaramente che, attraverso la TEA, l'emozione predominante è quella neutrale. Tuttavia, per scoprire eventuali pattern nascosti, è stato opportuno ricostruire la medesima tabella senza considerare la variabile 'neutral', data l'elevata presenza.

Emozione	AGI e Sviluppo	Impatto Economico e Governance	Etica e Sicurezza
anger	26.41%	25.16%	28.17%
joy	20.85%	20.50%	20.37%
sadness	20.74%	20.00%	16.21%
surprise	18.76%	19.89%	16.81%
fear	11.03%	12.70%	17.00%
disgust	2.20%	1.75%	1.44%

Tabella 3.12: Distribuzione percentuale delle emozioni nei diversi macro-topic

I risultati ottenuti mostrano un panorama emotivo simile per tutti i macro argomenti.

- AGI e sviluppo tecnologico: in questo caso, l'emozione più frequente è quella della rabbia (26,41%). A seguire troviamo altre due emozioni presenti in maniera quasi omogenea. Più precisamente, gioia (20,85%) e tristezza (20,74%).

- Impatto Socio-Economico e Governance: come nel tema precedente, anche in questo caso è la rabbia l'emozione maggiormente presente, con un valore del 25,16%. Si possono trovare anche in questo caso altre tre emozioni con valori elevati ed omogenei. Più precisamente, gioia (20,50%), tristezza (20,00%) e sorpresa (19,89%). L'elevato valore della sorpresa in questo topic potrebbe essere riferito alle reazioni a nuove leggi o all'impatto dell'IA nel mondo del lavoro.

- Rischi, Etica e Sicurezza: come per le altre aree, anche in questa le emozioni dominanti sono la rabbia (28,17%), valore più alto, e la gioia (20,37%). Tuttavia, anche l'emozione della paura è frequente in questo macro argomento, raggiungendo un valore percentuale pari al 17,00%. A differenza degli altri due macro argomenti si può affermare che questo gruppo è caratterizzato da discussioni polarizzate da sentimenti negativi, dove paura e rabbia predominano sugli altri.

L'emozione del disgusto, invece, tende a essere quella meno rappresentata in ogni categoria presente.

Lunghezza del testo e emozione suscitata
Un ulteriore analisi è stata condotta per scoprire se esistesse un legame tra la lunghezza dei commenti e l'emozione del commento stesso. I commenti sono stati suddivisi in quattro categorie basate sul conteggio delle parole:

- Molto brevi: fino a 20 parole.

- Brevi: da 21 a 50 parole.

- Medi: da 51 a 100 parole.

- Lunghi: oltre le 100 parole.

Si osservi il seguente grafico:

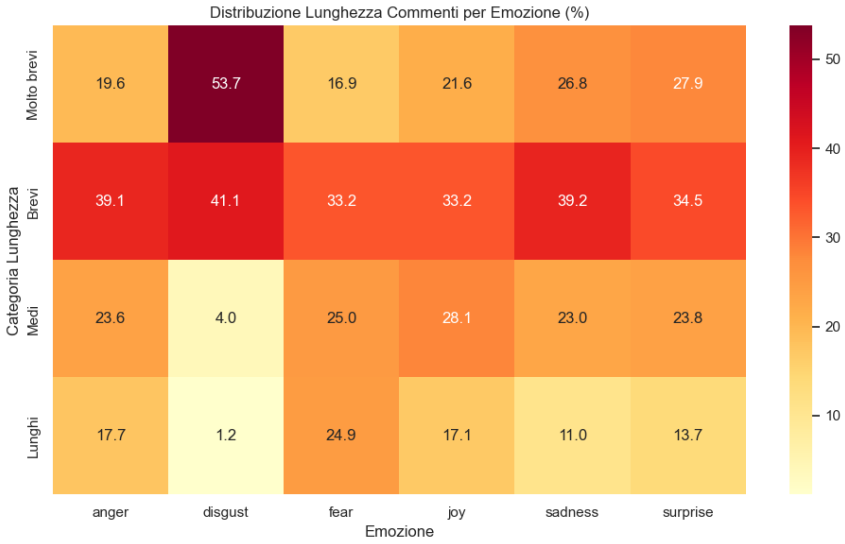

Figura 3.10: Distribuzione della lunghezza dei commenti per emozione

La Figura 3.10 rivela un vero e proprio schema dietro ogni emozione. Più nel dettaglio:

- Disgusto: questa emozione è l'emozione più sintetica tra tutte. Oltre il 53,7% dei commenti che esprimono disgusto sono 'molto brevi', mentre il 41,1% sono 'brevi'. In totale, quindi, il 94,8% dei commenti che esprimono disgusto non supera le 50 parole. Questo suggerisce che il disgusto sia un giudizio netto, senza alcuna spiegazione. Possono essere commenti diffusi sui social come 'creepy', 'gross' o 'that sucks'.

- Paura: opposta al disgusto, troviamo invece la paura, che presenta testi 'medi' (25,00%) e 'lunghi' (24,9%) più frequentemente rispetto a tutte le altre emozioni. Si può quindi ipotizzare che, a differenza delle altre emozioni, la paura necessiti di essere articolata in maniera più complessa, per descrivere, ad esempio, le proprie preoccupazioni riguardo ad un fenomeno.

- Gioia: questa emozione appare distribuita in maniera piuttosto equa tra i vari testi, a differenza di emozioni come il disgusto e la paura. Quindi, si tratta di testi che possono esprimere brevi esclamazioni come 'Fantastic' oppure 'Really good', o testi più articolati.

- Rabbia, Tristezza e sorpresa: queste tre emozioni si distribuiscono tutte in maniera piuttosto simile. Per tutti, la lunghezza principale di un testo è 'breve', quindi non hanno la necessità di essere articolate come la paura e non sono parole singole che suscitano un'emozione, come accade per il disgusto.

Analisi dell'efficienza emotiva

Non tutte le emozioni generano lo stesso livello di reazione da parte della community, per questo motivo, è stata calcolata l'efficienza emotiva, un rapporto tra lo score medio di un commento e l'intensità media dell'emozione di esso. Si osservi la seguente tabella:

Emozione	Emotion Score	Score Comment	Efficienza
Disgust	0.617	39.759	64.438
Anger	0.692	34.761	50.227
Surprise	0.592	28.839	48.676
Sadness	0.645	30.103	46.689
Joy	0.657	27.395	41.716
Fear	0.758	28.185	37.167

Tabella 3.13: Efficienza emotiva (rapporto tra intensità e score dei commenti)

La Tabella 3.13 rivela che le emozioni più efficaci nel generare un engagement sono quelle del 'disgusto' (64,438) e della 'rabbia' (50,227). Come ci si poteva aspettare, una delle emozioni con l'efficienza minore è quella della 'gioia' (41,715). Tuttavia, il risultato più sorprendente è quello della 'paura', che, contrariamente a quanto si potrebbe pensare, risulta essere il meno efficiente in assoluto (37,167). Un'ipotesi è che i sentimenti basati sulla paura possano spesso essere percepiti come allarmistici, generando meno consenso rispetto a critiche dirette e concrete, come quelle espresse dalla 'rabbia'. In generale, da questa tabella si può affermare che i commenti sfavorevoli nei confronti dell'IA riescono ad ottenere maggiore supporto da parte della community. Al contrario, i commenti che esprimono 'gioia' generano un engagement nettamente inferiore.

Relazione tra engagement ed emozione

Un ulteriore analisi è stata quella di esaminare la distribuzione delle emozioni in relazione al livello di engagement dei commenti. Si è deciso di utilizzare il valore mediano degli score come soglia per i commenti. Più precisamente, i commenti sono stati suddivisi in due gruppi:

- Basso engagement: con score inferiore alla mediana.
- Alto engagement: con score uguale o superiore alla mediana.

Si osservi il seguente grafico, che racchiude i principali risultati:

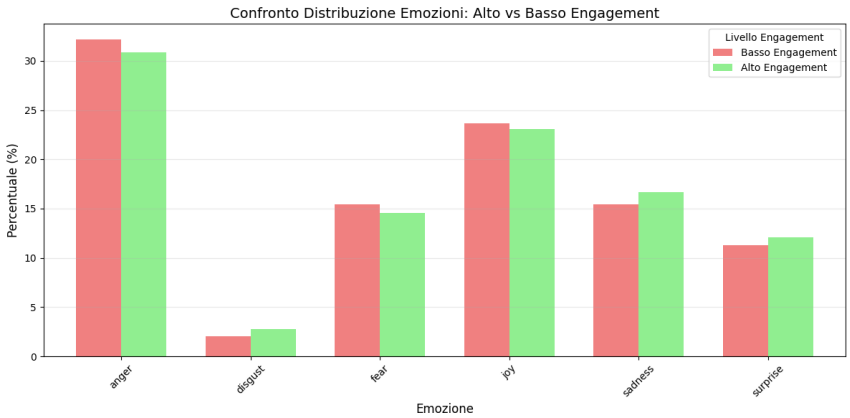

Figura 3.11: Confronto tra post ad alto e basso engagement

La Figura 3.11 mostra come i due gruppi appaiano molto simili, con sottili variazioni. Ad esempio, i commenti con un alto engagement tendono ad avere una

porzione superiore di 'disgusto' e 'tristezza'. Invece, le altre emozioni, come 'rabbia' e 'paura', tendono ad essere maggiormente rappresentate nei commenti a basso engagement. Per determinare se i risultati ottenuti da questa analisi fossero statisticamente rilevanti, è stato eseguito un test del Chi-Quadrato. Il test ha prodotto un valore del Chi-Quadrato di 16,6634 con un p-value di 0,0052. Dal momento che il valore del p-value è inferiore alla soglia di significatività, si rigetta l'ipotesi nulla, confermando quindi che i risultati ottenuti siano statisticamente significativi.

Tipologia di autore ed emozione suscitata
Un ulteriore analisi è stata quella di confrontare la distribuzione delle emozioni tra gli autori noti e gli autori non noti. Si osservi il seguente grafico:

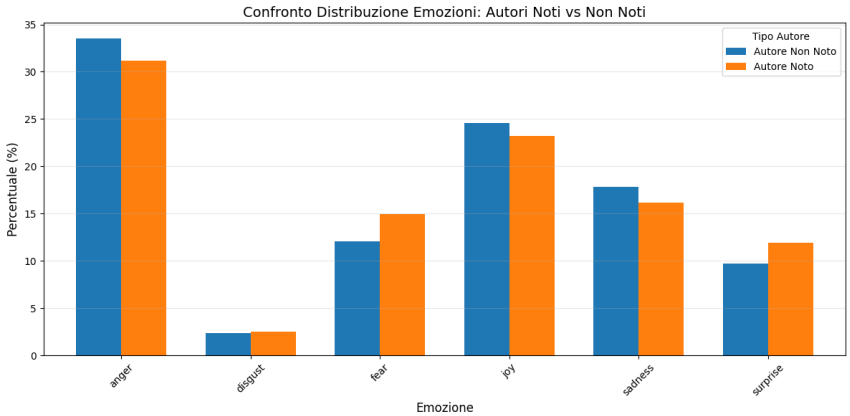

Figura 3.12: Autori noti vs autori non noti

Dall'analisi della Figura 3.12 si possono notare delle leggere tendenze. Gli autori noti tendono ad avere valori superiori per emozioni come 'disgusto', 'paura' e 'sorpresa'. Le restanti emozioni, come 'gioia' o 'rabbia', tendono invece ad essere leggermente migliori nei commenti degli autori non noti. Tuttavia, al fine di scoprire se queste leggere tendenze siano significative o più semplicemente fluttuazioni causate dal campione in studio, è stato condotto anche in questo caso un test del Chi-Quadrato. Il test ha prodotto un valore di Chi-Quadrato di 8,7262 con un p-value di 0,1205. Poiché il valore del p-value è superiore alla soglia di significatività, si accetta l'ipotesi nulla. Quindi, non esiste una differenza statisticamente significativa nella distribuzione delle emozioni tra gli autori noti e quelli sconosciuti. Le tendenze ipotizzate rimangono semplici ipotesi che non possono essere verificate.

3.3 Analisi del topic modeling

Risultati generali del topic modeling

Come anticipato nel capitolo sulle metodologie, si hanno un totale di 7 topics, più precisamente:

1. Topic 0 (jobs, ai, job, says): Impatto dell'IA nel mondo del lavoro e nell'occupazione. Il tema di questo topic si concentra sull'impatto dell'IA sui posti di lavoro. Il termine 'says' indica che probabilmente i post raccolti in questo cluster riguardano opinioni o dichiarazioni di esperti.

2. Topic 1 (safety, ai, google, world): Sicurezza globale dell'IA e il ruolo di Google. Il tema di questo topic riguarda la sicurezza legata all'IA a livello mondiale ('world').

3. Topic 2 (regulation, regulations, house, state). Regolamentazione e governance dell'IA. Quando si utilizza il termine "House" si fa spesso riferimento alla "White House" o alle istituzioni governative americane, quindi, si può ipotizzare che questo topic riguardi le leggi e i piani governativi sul tema dell'IA.

4. Topic 3 (models, ethical, human, ethics): Etica e sviluppi di modelli IA responsabili. In questo caso, il focus è sull'etica applicata ai modelli di intelligenza artificiale. Probabilmente, gli articoli di questo cluster discutono la necessità di maggiore trasparenza nei modelli al fine di ridurre errori.

5. Topic 4 (openai, agi, training, law): OpenAI: Addestramento dei dati e implicazioni legali. In questo caso, il focus è sull'OpenAI una delle aziende principali nel mondo dell'IA. Quindi, fa probabilmente riferimento alle sue strategie (law) e ai suoi metodi per addestrare i modelli (training).

6. Topic 5 (china, global, world, warns): Geopolitica dell'IA, il ruolo della cina. Questo topic affronta la geopolitica dell'intelligenza artificiale. La parola chiave 'china' e le parole 'global' e 'world' fanno pensare ad una discussione sullo sviluppo globale.

7. Topic 6 (understand, thinks, godfather, researchers): L'IA è in grado di pensare e comprendere automaticamente?. Questo cluster sembra essere di natura filosofica e accademica. Indica che il dibattito si focalizzi sulla comprensione e sulla possibilità di pensare in maniera autonoma delle macchine.

8. Topic -1 (ai, chatgpt, future, people): Discussioni generali sull'IA. È importante tenere conto che questo è un topic contenente outliers o temi misti. Le parole principali sono molto generali e quindi suggeriscono discussioni ampie che riguardano il futuro dell'IA. Tuttavia, questo topic non presenta alcun tipo di focus in nessun ambito, come invece è presente nei topic precedenti.

Analisi del sentiment per topic

Dopo aver identificato, tramite il topic modeling, i principali cluster all'interno dei post di reddit, lo studio si è concentrato su un'analisi tra il topic riscontrato e il sentiment. Più precisamente, è stato calcolato il sentiment medio per ciascun topic e la percentuale dei vari sentiment per ogni gruppo, fornendo una visione sulla polarità. Si osservino i seguenti grafici:

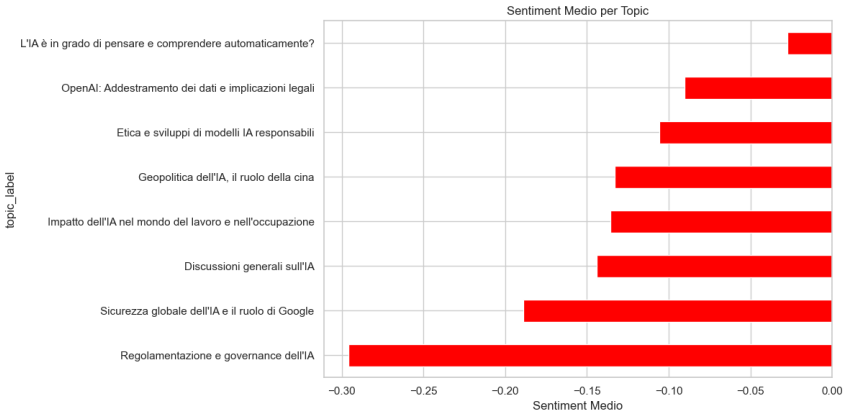

Figura 3.13: Percentuale di sentiment medio per ciascun topic

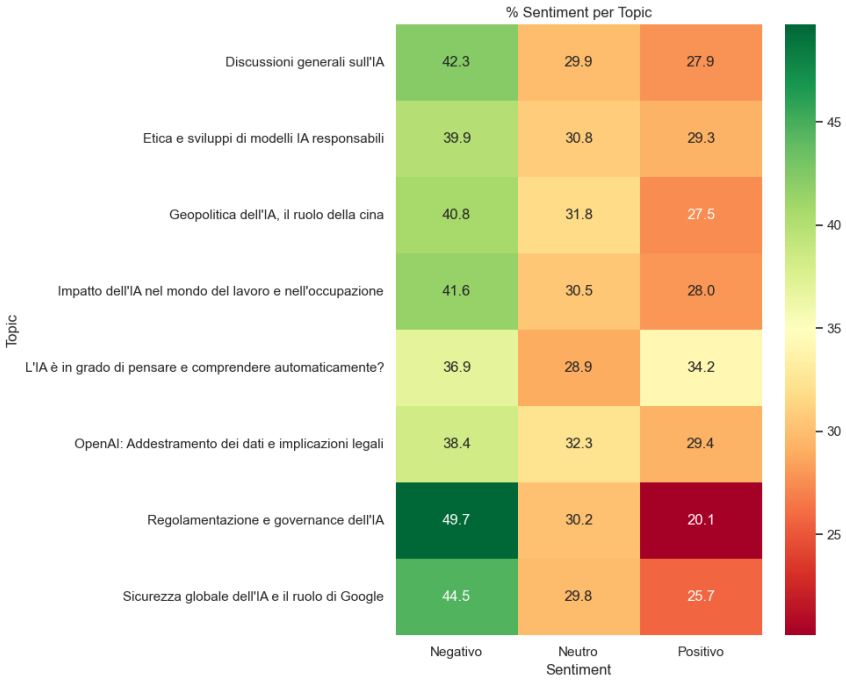

Figura 3.14: Percentuale di sentiment per ciascun topic

La Figura 3.13 mostra la percentuale del sentiment medio per ciascun topic. Come si può notare, tutti i valori sono inferiori allo 0, mostrando una prevalenza di sentiment negativo in tutti i temi e indicando che, indipendentemente dall'argomento, le conversazioni tendono ad essere pessimistiche.

La Figura 3.14 conferma questo pattern. Sono due i topic principali in cui emerge questo fenomeno: "Regolamentazione e governance dell'IA" in cui il 48,7% dei commenti è negativo e "Sicurezza globale dell'IA e il ruolo di Google" con una percentuale del 44,5%. L'unica eccezione che presenta un sentiment positivo superiore al 30% è "L'IA è in grado di pensare e comprendere automaticamente?" con un valore percentuale del 34,2% positivo, contro il 36,9% negativo.

Analisi delle emotion per topic

Sicuramente, delle analisi più interessanti sono quelle che riguardano le emozioni per i singoli topic. Al fine di cogliere maggiormente eventuali polarità, è stato deciso di creare una heatmap escludendo la variabile "neutrale".

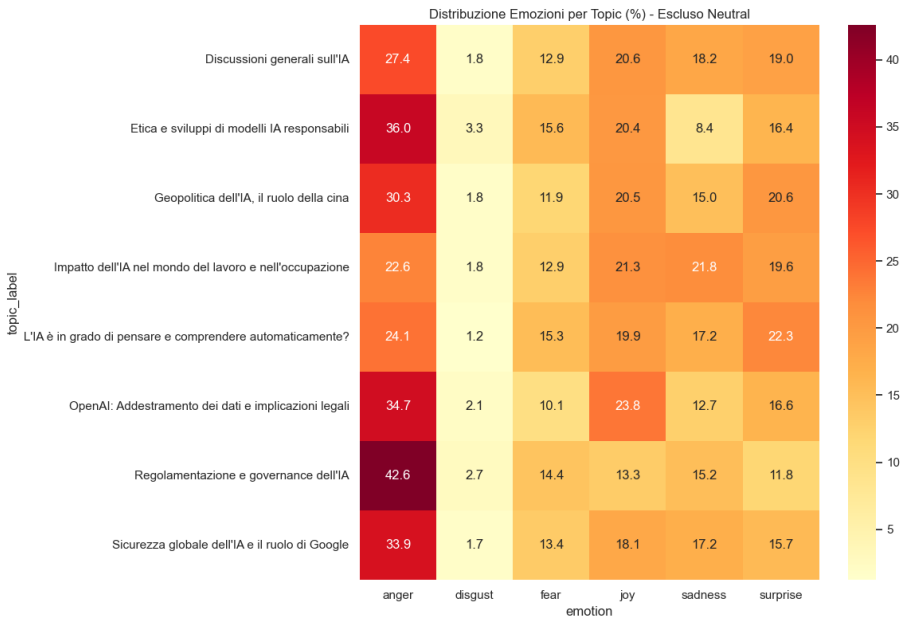

Figura 3.15: Distribuzione delle emozioni per topic

Al fine di fornire un'analisi completa, è stato deciso di analizzare questo grafico, esaminando ogni topic.

- Etica e sviluppi di modelli IA responsabili: Come per tutti i temi trattati, il sentimento più frequente è quello della rabbia, con una percentuale del 36%. Inoltre, la paura rappresenta in questo topic una percentuale più elevata (15,6%) rispetto agli altri topic, anche se è piuttosto bassa rispetto a quanto ci si poteva aspettare.

- Geopolitica dell'IA, il ruolo della cina: Il dibattito della geopolitica è dominato dall'emozione della rabbia (30,3%). Inoltre, le altre emozioni che caratterizzano questo topic sono sorpresa (20,6%) e gioia (20,5%). Quindi, si può dire che l'avanzamento tecnologico non genera solamente rabbia, ma anche stupore per i risultati ottenuti.

- Impatto dell'IA nel mondo del lavoro e nell'occupazione: Sia la rabbia(22,6%) che la gioia (21,3%) sono sentimenti fortemente presenti in questo topic. Nonostante ciò, la vera particolarità di questo topic è la forte frequenza del sentimento della tristezza, con un valore del 21,8%, il più alto tra tutti i topic. Questa emozione non è altro che un riflesso delle preoccupazioni di numerosi utenti riguardo al rischio di perdita di posti di lavoro.

- L'IA è in grado di pensare e comprendere automaticamente?: Come nel caso del topic precedente, anche in questo caso sia la rabbia (24,1%) che la gioia (19,9%) sono tra i sentimenti più frequenti. Tuttavia, la vera particolarità di questo topic è l'elevata presenza di sorpresa pari al 22,3%.

- OpenAI: Addestramento dei dati e implicazioni legali: Questo topic è dominato dalla rabbia (34,7%) e dalla gioia (23,8%). Questo topic, quindi, coglie l'andamento generale dei nostri dati tra sentiment negativo e positivo.
- Regolamentazione e governance dell'IA: Questo è il topic che mostra un profilo emotivo più polarizzato. L'emozione predominante è quella della rabbia, che raggiunge il suo picco con un valore percentuale del 42,6%. In questo topic le persone mostrano la loro frustrazione nei confronti delle iniziative politiche che dovrebbero controllare lo sviluppo e l'utilizzo dell'IA.
- Sicurezza globale dell'IA e il ruolo di google: Come è avvenuto per gli altri topic anche in questo il sentiment principale è quello della rabbia (33,9%). Tuttavia, è caratterizzato da alti valori di gioia (18,1%) e tristezza (17,2%).

3.4 Analisi dello XAI

Scelta del modello

I risultati sul test set per la scelta del modello evidenziano come random forest abbia un'accuracy migliore rispetto al XGBoost. Più precisamente:

Tabella 3.14: Prestazioni dei Modelli di Classificazione

Modello	Accuracy (%)	F1-Score
Random Forest	72,93%	0.7012
XGBoost	72,83%	0.7004

Come mostrato nella Tabella 3.14, il modello random forest e XGBoost mostrano metriche molto simili tra loro, con un miglioramento del random forest dello +0,1% dell'accuracy e del +0,0008% di F1-Score. Più precisamente, gli iperparametri emersi tramite il grid search sono:

- class_weight: balanced
- max_depth: None
- min_samples_leaf: 1
- min_samples_split: 2
- n_estimators: 300

Analisi dello SHAP

Interpretabilità globale
L'analisi dell'importanza globale rivela le variabili che influenzano maggiormente le decisioni del modello nel distinguere gli score (alto, medio e basso). Si osservi la seguente immagine:

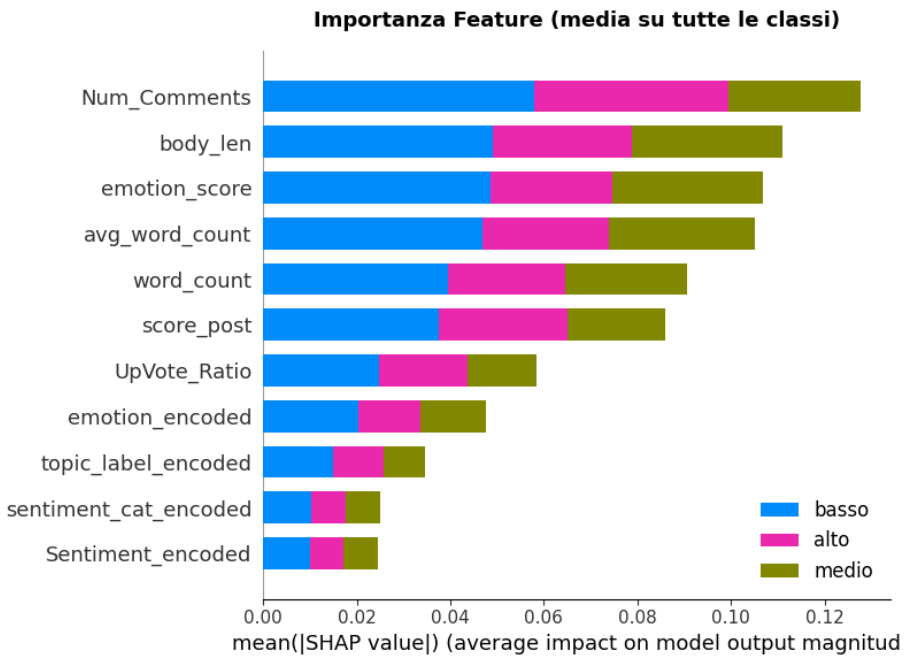

Figura 3.16: Importanza globale delle variabili

Dalla Figura 3.16 emerge che la variabile 'Num_Comments' è il predittore più influente, suggerendo che il numero di commenti all'interno dei post aiuta a comprendere lo score stesso del commento. Altre variabili principali sono 'body_len', 'word_count' e 'avg_word_count', indicando che anche la struttura stessa di un commento, come la sua lunghezza, aiutano a stabilire lo score finale del commento. Invece, le variabili che riguardano direttamente il sentiment come 'emotion_score' o le variabili codificate dei sentiment e delle emozioni, giocano anch'esse un ruolo significativo nell'assegnazione finale. Al fine di osservare se i risultati ottenuti fossero maggiormente robusti, è stato effettuato un confronto tra i valori SHAP e le feature importance del random forest. Si osservi il seguente grafico:

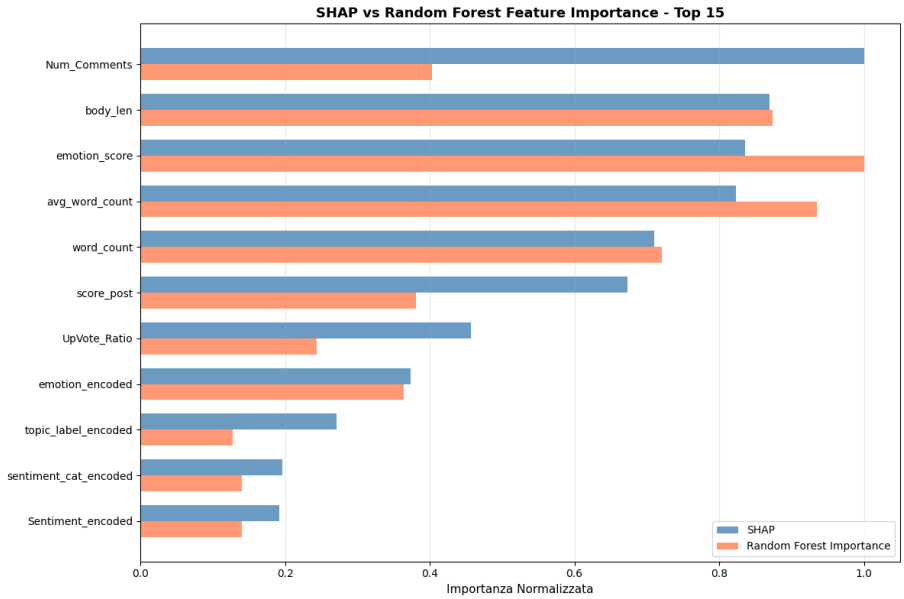

Figura 3.17: Confronto tra valori SHAP e Random Forest

Dalla Figura 3.17 emerge che lo SHAP e il random forest tendono a catturare aspetti diversi nel processo decisionale. Questa differenza rafforza l'utilità dello SHAP. La feature importance del random forest tende a favorire le variabili numeriche continue, mentre i valori SHAP riflettono meglio l'impatto di ogni variabile sulla classe da predire. La divergenza principale dei due metodi si riscontra soprattutto in 'Num_Comments' che l'analisi SHAP identifica come variabile fondamentale, mentre il random forest gli attribuisce un peso decisamente inferiore, preferendo altre variabili come 'emotion_score'.

Risultati dei beeswarm plots

I beeswarm plots offrono una visione di come ciascuna feature influisca la probabilità di appartenenza a ciascuna classe. Si osservino i successivi tre grafici:

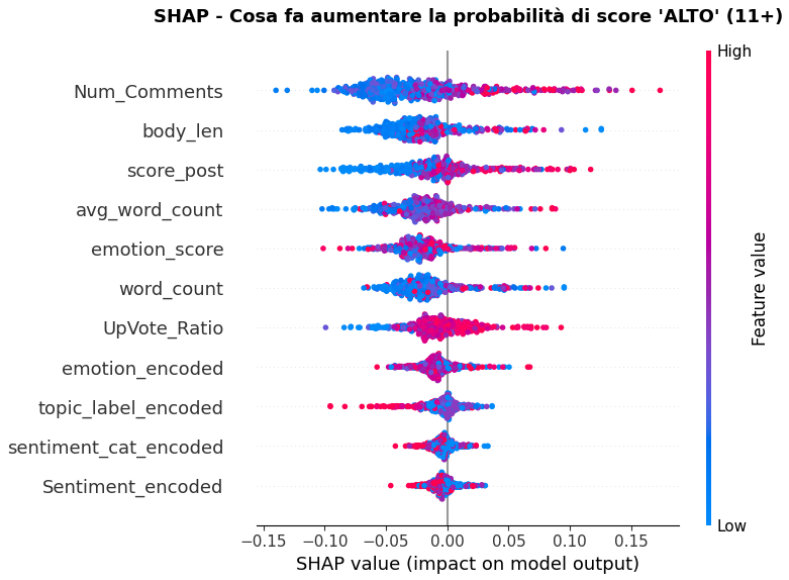

Figura 3.18: Beeswarm - alto

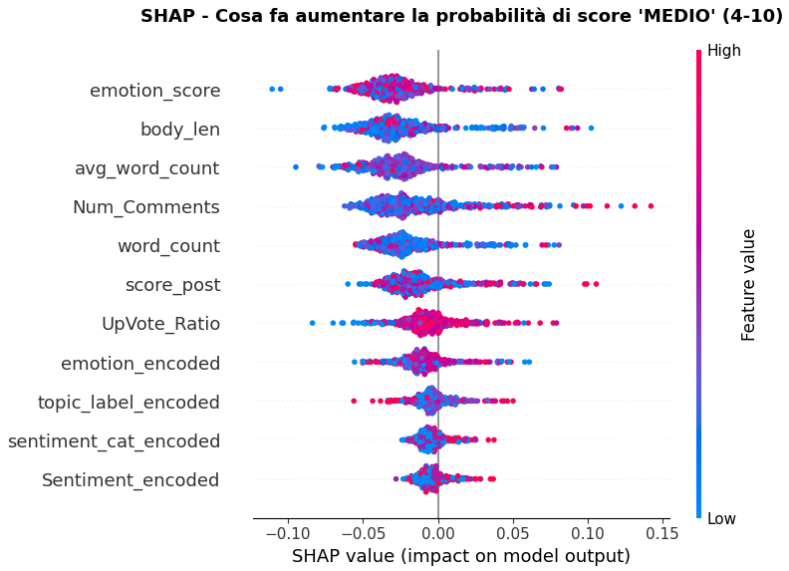

Figura 3.19: Beeswarm - medio

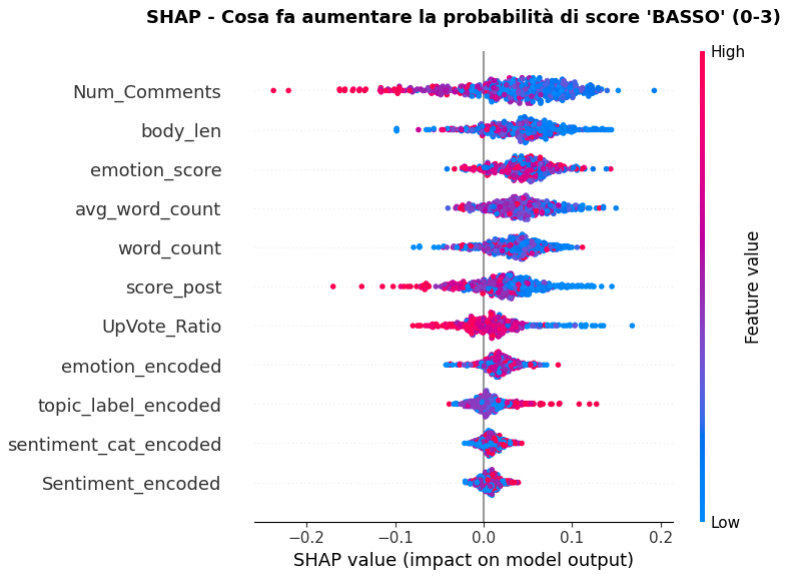

Figura 3.20: Beeswarm - basso

- Classe 'Alto' (Score 11+): Dalla Figura 3.18 si nota chiaramente che i valori più alti, espressi dai punti rossi, appartengono alle variabili 'Num_Comments', 'score_post' e 'UpVote_Ratio'. Tali punti appaiono principalmente sulla destra, indicando valori SHAP positivi. Quindi, post con molti commenti, con score elevati e un alto ratio di upvote hanno un'alta probabilità di classificare il commento nella classe 'Alto'.

- Classe 'Medio' (Score 4-10): Dalla Figura 3.19 si può notare che la classe media è quella più difficile da prevedere. Infatti, non si riescono a notare pattern ben definiti. Inoltre, i valori SHAP si trovano in un intervallo molto ristretto tra -0,05 e +0,05, che rafforza l'idea di una minore certezza predittiva. In questa classe si nota che la variabile principale diventa 'emotion_score', suggerendo che il contenuto emotivo pesa maggiormente rispetto alle metriche del testo stesso.

- Classe 'Basso' (Score 0-3): Dalla Figura 3.20 emerge un comportamento opposto rispetto alla classe 'Alto'. A differenza di quest'ultima, nella classe 'Basso' i punti rossi di 'Num_Comments', 'Score_post' e 'UpVote_Ratio' tendono ad essere sulla sinistra (SHAP value negativi). Quindi, i post privi di commenti e con score bassi tendono a portare il punteggio di un commento nella classe 'Basso'.

Risultati dell'analisi dei singoli casi

Come ultimo passaggio, si sono svolti i waterfall plots, che hanno permesso di analizzare singole osservazioni (campioni), mostrando come il modello sia giunto alla previsione finale. Anche in questo caso, si è deciso di utilizzare tre waterfall plots, uno per ogni classe di previsione.

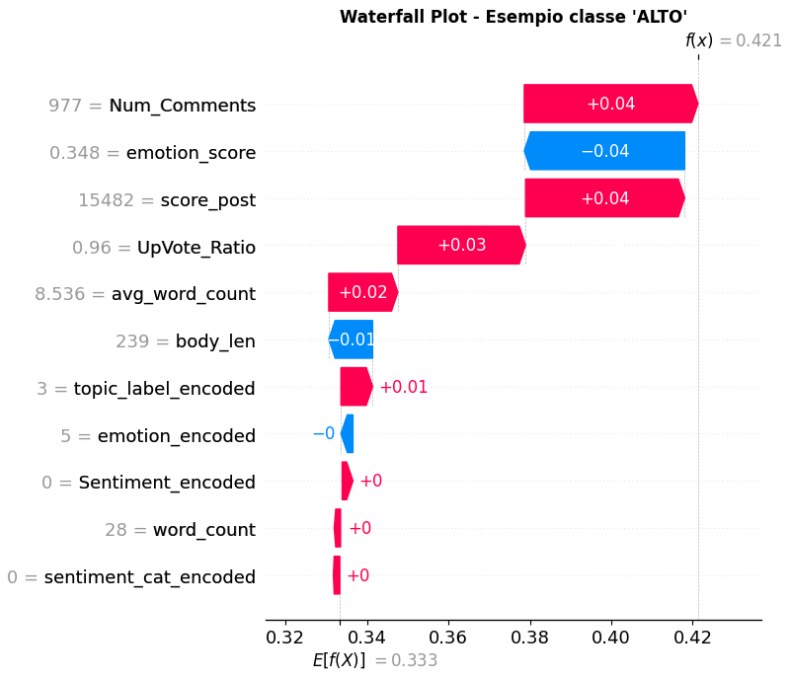

Figura 3.21: Waterfall - alto

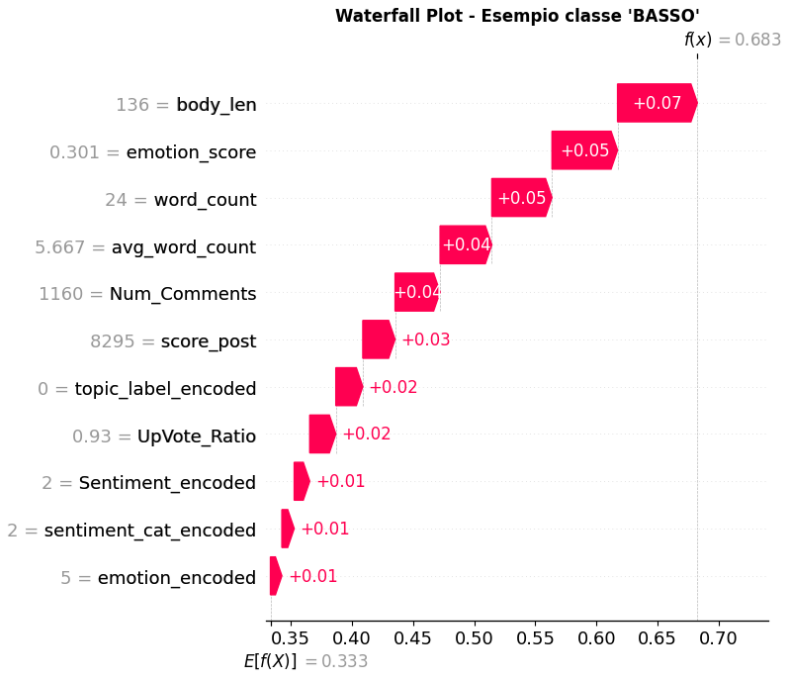

Figura 3.22: Waterfall - medio

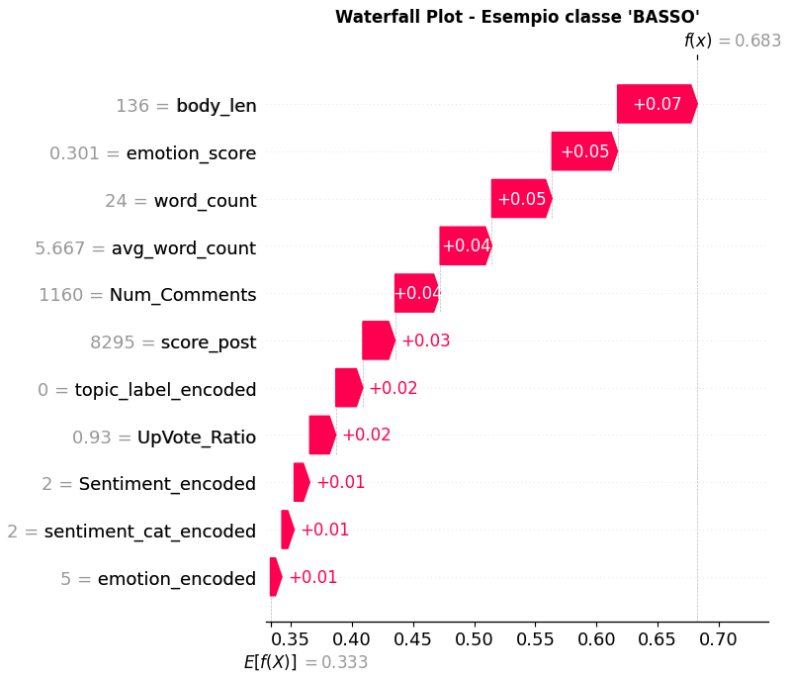

Figura 3.23: Waterfall - basso

- Classe 'Alto': Dalla Figura 3.21 si può notare che si parte da una probabilità di base dello 0,333. Il modello ha predetto una probabilità finale dello 0,421 e i principali contributi sono stati 'Num_comments', 'score_post' e 'UpVote_Ratio'. È interessante notare che in questo caso l'emotion_score abbia agito in maniera negativa, frenando la previsione verso questa classe.

- Classe 'Medio': Dalla Figura 3.22 si nota che la probabilità finale è dello 0,58. Anche in questo caso sono state 'Num_comments' e 'score_post' quelle che hanno aumentato maggiormente la probabilità.

- Classe 'Basso': Dalla figura 3.23 si può osservare che la probabilità finale è di 0,683 (ben sopra la media di 0,333). Tutte le variabili hanno contribuito in maniera positiva a questa previsione, come 'body_len', 'emotion_score' o 'word_count'. Queste variabili possono indicare che il commento in analisi sia breve e con uno score emotivo basso, indirizzandolo quindi verso una classificazione finale del commento nella classe bassa.

4 Discussione finale e conclusioni

4.1 Discussione dei principali risultati

L'obiettivo della tesi era quello di andare oltre una visione superficiale della percezione pubblica dell'IA, scavando più a fondo per scoprire topic nascosti, le emozioni vere provate nei commenti e i fattori che influenzavano il punteggio di un commento. L'analisi ha quindi permesso di rispondere ad alcune domande chiave:

Quali sono i temi dominanti che strutturano le conversazioni pubbliche sull'IA?
L'analisi del topic ha rilevato che il dibattito pubblico è frammentato in vari tipi di conversazioni distinte e specifiche. Tra i temi più discussi dagli utenti di Reddit ci sono le discussioni sull'impatto dell'IA nel mondo del lavoro, le strategie di aziende specifiche come OpenAI o Klarna fino ad arrivare a questioni che riguardano la geopolitica globale. Ciò dimostra che i dibattiti analizzano ogni sfumatura dell'IA dalle pratiche del mondo del lavoro, all'economia, alla sicurezza, alle politiche da attuare, fino ai discorsi etici.

Per i vari topic quale è l'emozione suscitata?
L'emozione predominante in tutti i topic è quella della rabbia, specialmente nei dibattiti sulla regolamentazione e governance. Allo stesso tempo, emergono risultati interessanti. Ad esempio, la tristezza è fortemente presente quando si parla di IA e il suo impatto sull'occupazione, indicando una reazione legata ad ansie personali e alla preoccupazione per il proprio futuro. Si può citare anche come la paura sia maggiormente presente nei topic che riguardano l'etica e lo sviluppo di modelli responsabili. Infine, è interessante scoprire come la sorpresa e la gioia siano significative nei topic legati agli avanzamenti tecnologici e a quelli più filosofici.

Quali elementi rendono un'opinione più influente di altre?
I risultati dello XAI hanno rilevato una dinamica poco intuitiva. Sebbene ci si potrebbe aspettare che l'impatto emotivo influenzi fortemente il punteggio finale di un commento, tramite lo XAI è stato possibile scoprire che in realtà sono le metriche contestuali del post stesso ad influenzare fortemente lo score, come il numero dei commenti sotto il post o lo score stesso del post. Quindi si può dire che l'influenza di un commento è determinata, prima di tutto, da quanto un post sia popolare e, quindi, da quanto attiva sia una discussione. Inoltre, basandoci sempre sui risultati dello XAI, si nota che anche la lunghezza del commento è un fattore rilevante, indicando quindi che la community premia commenti lunghi ed articolati.
Confrontando i risultati ottenuti con lo stato dell'arte, si conferma l'importanza di analizzare i sentimenti come "sensori" dell'opinione pubblica, possibilmente superando il limite di semplice polarità tra positivo e negativo, ma utilizzando le emozioni.

4.2 Limiti dello studio

Un'aspetto fondamentale è riconoscere i limiti della ricerca per poterne tenere conto. I limiti principali sono due:

1. Limiti legati al campione: Il primo, e probabilmente il più importante, riguarda la generalità dei risultati ottenuti. Prima di tutto, i dati provengono da un'unica piattaforma social, Reddit, e da un unico subreddit, r/Futurology. Inoltre, gli utenti appartenenti a tale subreddit non sono rappresentativi della popolazione globale, ma presentano un forte bias demografico (giovani, maschi, nordamericani) e di interesse, generalmente tendono ad essere informati nel mondo della tecnologia.

2. Limiti metodologici: Il secondo limite riguarda i metodi utilizzati. Un'esempio è, che, il modello ensemble per la Sentiment Analysis, pur raggiungendo un'accuracy del 70% sul campione selezionato, fatica a interpretare commenti contenenti sarcasmo o ironia. Lo stesso ragionamento può essere fatto sull'emotion model, che aveva lo scopo di identificare le emozioni specifiche.

4.3 Direzioni per una ricerca futura

La comprensione dei limiti dello studio permette di identificare alternative per migliorare le analisi.

1. Una soluzione al limite legato al campione può essere quella di estendere il campione stesso. Diventa necessario non solo utilizzare più subreddit presenti su Reddit, ma sarebbe ancora più corretto l'utilizzo di più social network. Ad esempio, l'utilizzo di commenti provenienti da Twitter o Facebook permetterebbe di cogliere le opinioni degli adulti, mentre raccogliere informazioni da social come Instagram o Tik Tok permette di avere una visione più giovanile.

2. Una soluzione alle metodologie utilizzate, potrebbe essere la possibilità di migliorare i modelli stessi tramite, ad esempio, fine-tuning. Più precisamente, si potrebbe selezionare un campione di 500/1000 osservazioni etichettate manualmente e successivamente procedere a migliorare il modello scelto, addestrandolo su queste osservazioni.

4.4 Conclusioni

Il dibattito pubblico sull'Intelligenza Artificiale non è una semplice contrapposizione tra visione ottimistica e visione pessimistica, ma un dialogo complesso. L'analisi di oltre 50.000 commenti dalla piattaforma Reddit ha svelato come il panorama emotivo sia strettamente legato ai temi trattati: la rabbia domina le discussioni sulla governance, mentre la tristezza domina quelle sull'impatto lavorativo. Questo studio, quindi, offre una visione più realistica della percezione pubblica, spostando il focus dalla semplice misurazione del sentiment alla spiegazione delle dinamiche del discorso online. Comprendere a fondo queste dinamiche è un passo fondamentale. Per costruire un futuro in cui l'IA sia non solo innovativa, ma anche degna di fiducia, il ritmo del progresso tecnologico deve evolversi con il tempo che la società ha bisogno per comprenderlo, adattarsi e accettarlo.

Elenco delle figure

3.1 Tipologia degli elementi presenti nel DataFrame 35
3.2 Distribuzione delle variabili numeriche nel dataset 35
3.3 Matrice di correlazione delle variabili numeriche 36
3.4 Andamento temporale dei commenti 37
3.5 WordCloud dei commenti 38
3.6 Top 10 parole più frequenti 38
3.7 Bigrammi dei commenti 39
3.8 Trigrammi dei commenti 39
3.9 Distribuzione dei sentiment nei commenti 40
3.10 Distribuzione della lunghezza dei commenti per emozione 45
3.11 Confronto tra post ad alto e basso engagement 46
3.12 Autori noti vs autori non noti 47
3.13 Percentuale di sentiment medio per ciascun topic 49
3.14 Percentuale di sentiment per ciascun topic 49
3.15 Distribuzione delle emozioni per topic 50
3.16 Importanza globale delle variabili 52
3.17 Confronto tra valori SHAP e Random Forest 52
3.18 Beeswarm - alto 53
3.19 Beeswarm - medio 53
3.20 Beeswarm - basso 54
3.21 Waterfall - alto 55
3.22 Waterfall - medio 55
3.23 Waterfall - basso 56

Elenco delle tabelle

2.1 Percentuali per modello 27
3.1 Statistiche sui Commenti e sui Punteggi 33
3.2 Statistiche sulle Lunghezze dei Commenti 33
3.3 Statistiche sui Commenti e sui Punteggi per Macro-Topic 34
3.4 Statistiche sulle Lunghezze dei Commenti per Macro-Topic 34
3.5 Score medio per classe di sentiment 41
3.6 Matrice di correlazione di Pearson 41
3.7 Matrice di correlazione di Spearman 41
3.8 Sentiment medio nei post con elevata partecipazione 41
3.9 Controversia e Sentiment 42
3.10 Distribuzione delle emozioni 43
3.11 Distribuzione percentuale delle emozioni nei diversi macro-topic . . . 43
3.12 Distribuzione percentuale delle emozioni nei diversi macro-topic . . . 44
3.13 Efficienza emotiva (rapporto tra intensità e score dei commenti) . . . 46
3.14 Prestazioni dei Modelli di Classificazione 51

Bibliografia

[1] Daron Acemoglu and Pascual Restrepo. Automation and new tasks: How technology displaces and reinstates labor. *Journal of economic perspectives*, 33(2):3–30, 2019.

[2] Rubayyi Alghamdi and Khalid Alfalqi. A survey of topic modeling in text mining. *International Journal of Advanced Computer Science and Applications*, 6(1), 2015.

[3] Cecilia Ovesdotter Alm, Dan Roth, and Richard Sproat. Emotions from text: machine learning for text-based emotion prediction. In *Proceedings of human language technology conference and conference on empirical methods in natural language processing*, pages 579–586, 2005.

[4] Santosh Kumar Bharti, S Varadhaganapathy, Rajeev Kumar Gupta, Prashant Kumar Shukla, Mohamed Bouye, Simon Karanja Hingaa, and Amena Mahmoud. Text-based emotion recognition using deep learning approach. *Computational Intelligence and Neuroscience*, 2022(1):2645381, 2022.

[5] David M Blei, Andrew Y Ng, and Michael I Jordan. Latent dirichlet allocation. *Journal of machine Learning research*, 3(Jan):993–1022, 2003.

[6] Anu Bradford. *The Brussels Effect: How the European Union Rules the World*. Oxford University Press, 2020.

[7] Erik Brynjolfsson and Andrew McAfee. *The second machine age: Work, progress, and prosperity in a time of brilliant technologies*. WW Norton & company, 2014.

[8] Joy Buolamwini and Timnit Gebru. Gender shades: Intersectional accuracy disparities in commercial gender classification. In *Conference on fairness, accountability and transparency*, pages 77–91. PMLR, 2018.

[9] Lea Canales and Patricio Martínez-Barco. Emotion detection from text: A survey. In *Proceedings of the workshop on natural language processing in the 5th information systems research working days (JISIC)*, pages 37–43, 2014.

[10] Stephen Cave, Claire Craig, Kanta Dihal, Sarah Dillon, Jessica Montgomery, Beth Singler, and Lindsay Taylor. Portrayals and perceptions of ai and why they matter. 2018.

[11] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In

Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers), pages 4171–4186, 2019.

[12] Attilio Di Battista, Sam Grayling, Elselot Hasselaar, Till Leopold, Ricky Li, Mark Rayner, and Saadia Zahidi. Future of jobs report 2023. In *World Economic Forum*, pages 978–2, 2023.

[13] Ethan Fast and Eric Horvitz. Long-term trends in the public perception of artificial intelligence. In *Proceedings of the AAAI conference on artificial intelligence*, volume 31, 2017.

[14] Luciano Floridi. *La quarta rivoluzione: come l'infosfera sta trasformando il mondo*. Raffaello Cortina Editore, 2017.

[15] Luciano Floridi. *Etica dell'intelligenza artificiale: Sviluppi, opportunità, sfide*. Raffaello Cortina Editore, 2022.

[16] Maarten Grootendorst. Bertopic: Neural topic modeling with a class-based tf-idf procedure. *arXiv preprint arXiv:2203.05794*, 2022.

[17] Jochen Hartmann. Emotion english distilroberta-base. `https://huggingface.co/j-hartmann/emotion-english-distilroberta-base/`, 2022.

[18] Jake M Hofman, Amit Sharma, and Duncan J Watts. Prediction and explanation in social systems. *Science*, 355(6324):486–488, 2017.

[19] White House. *Blueprint for an ai bill of rights: Making automated systems work for the american people*. Nimble Books, 2022.

[20] Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. *Advances in neural information processing systems*, 30, 2017.

[21] Walaa Medhat, Ahmed Hassan, and Hoda Korashy. Sentiment analysis algorithms and applications: A survey. *Ain Shams engineering journal*, 5(4):1093–1113, 2014.

[22] Zohra Mehenaoui, Chayma Merabti, Houda Tadjer, and Yacine Lafifi. A comparative study on sentiment lexicons for automatic labeling. 2024.

[23] Brent Daniel Mittelstadt, Patrick Allo, Mariarosaria Taddeo, Sandra Wachter, and Luciano Floridi. The ethics of algorithms: Mapping the debate. *Big Data & Society*, 3(2):2053951716679679, 2016.

[24] Christoph Molnar. *Interpretable machine learning*. Lulu. com, 2020.

[25] Bostrom Nick. Superintelligence: Paths, dangers, strategies. *Strategies*, 2014.

[26] Brendan O'Connor, Ramnath Balasubramanyan, Bryan Routledge, and Noah Smith. From tweets to polls: Linking text sentiment to public opinion time series. In *Proceedings of the international AAAI conference on web and social media*, volume 4, pages 122–129, 2010.

[27] Bo Pang, Lillian Lee, et al. Opinion mining and sentiment analysis. *Foundations and Trends® in information retrieval*, 2(1–2):1–135, 2008.

[28] Sancheng Peng, Lihong Cao, Yongmei Zhou, Zhouhao Ouyang, Aimin Yang, Xinguang Li, Weijia Jia, and Shui Yu. A survey on deep learning for textual emotion analysis in social networks. *Digital Communications and Networks*, 8(5):745–762, 2022.

[29] Michael Veale. A critical take on the policy recommendations of the eu high-level expert group on artificial intelligence. *European Journal of Risk Regulation*, 11(1):e1, 2020.